

サバンナ便利

ソフトウェア開発の荒野を生き抜く

変更容易性と理解容易性を支える

自動テスト

Feb 10, 2024 @ YAPC::Hiroshima 2024

Takuto WADA

id:t-wada X @t_wada @twada @twada



X



X #yapc_i #yapc_japan

結論から

信頼性の高い実行結果に
短い時間で到達する状態を保つことで、
開発者に根拠ある自信を与え、
ソフトウェアの成長を持続可能にすること



Agenda



信頼性の高い

実行結果に


短い時間で到達する

状態を保つ

テストの自動化において、ITパフォーマンスの予測尺度となりうることが判明したのは次の2つ

1. 信頼性の高い自動テストを備えること
2. 開発者主体で受け入れテストを作成・管理し、手元の開発環境で簡単に再現・修正できること

『LeanとDevOpsの科学』 p.65 (※訳を一部変更)




信頼性の高い自動テストを備えること

テストに合格したソフトウェアであればリリース可能、不合格であれば重大な不具合がある、とチームが確信できるようなテストを実施していること

1. 誤検知（**偽陽性**: false positive）や見逃し（**偽陰性**: false negative）が多く、信頼性に欠けるテストスイートがあまりに多すぎる
2. 信頼度の高いテストスイートを作り上げる継続的な努力と投資は価値がある

『LeanとDevOpsの科学』 p.65（※訳を一部変更）



成功と失敗

テスト結果が プロダクトコードが	正しい	誤っている
	成功	失敗
成功		
失敗		

成功と失敗

テスト結果が プロダクトコードが	正しい	誤っている
	正しい	誤っている
成功	デプロイ、マージ	
失敗		

成功と失敗

テスト結果が プロダクトコードが	正しい	誤っている
	成功	失敗
成功		
失敗		問題箇所の特定と修復

成功と失敗、偽陽性と偽陰性

テスト結果が プロダクトコードが	正しい	誤っている
	成功	失敗
成功		
失敗	偽陽性	

成功と失敗、偽陽性と偽陰性

テスト結果が プロダクトコードが	正しい	誤っている
成功		偽陰性
失敗		

成功と失敗、偽陽性と偽陰性

テスト結果が プロダクトコードが	正しい	誤っている
	成功	失敗
成功	デプロイ、マージ	偽陰性
失敗	偽陽性	問題箇所特定と修復



Agenda

信頼性の高い



実行結果に

短い時間で到達する

状態を保つ

自動テストの実行結果は「情報」であり、情報の役割とは意思決定と行動を促すこと

テストの実行結果が促す行動とは、デプロイ、マージ、コードの修正など

成功時のアクション、失敗時のアクション

プロダクトコードが テスト結果が	正しい	誤っている
成功	デプロイ、マージ	
失敗		問題箇所の特定と修復

- テスト結果の出力と狙い
 - シグナルとして
 - 欠陥の絞り込みとして
 - ドキュメントとして
 - データとして
- 成功時の情報量をコントロールする技術
 - テスト名と構造
 - reporter
- 失敗時の情報量をコントロールする技術
 - テスト名と構造
 - テストサイズ（後述）
 - assertion, expectation, matcher



Agenda

信頼性の高い

実行結果に



短い時間で到達する

状態を保つ

テストサイズ: 自動テストと CI にフィットする 明確なテスト分類基準

皆さんにお伺いします



データベースにアクセスするのはユニットテスト? Yes / No

ネットワークにアクセスするのはユニットテスト? Yes / No



ファイルにアクセスするのはユニットテスト? Yes / No

現在時刻にアクセスするのはユニットテスト? Yes / No

依存先のモジュールに本物を使うのはユニットテスト? Yes / No




Unit Test の Unit って何？




Unit Test の Unit って何？

Sociable Tests



Often the tested unit relies on other units to fulfill its behavior

Solitary Tests



Some unit testers prefer to isolate the tested unit

Test Size: より曖昧さの少ない分類




Figure 11-2. Test sizes

O'REILLY
オライリー・ジャパン

Googleの ソフトウェア エンジニアリング

持続可能な
プログラミングを支える
技術、文化、プロセス



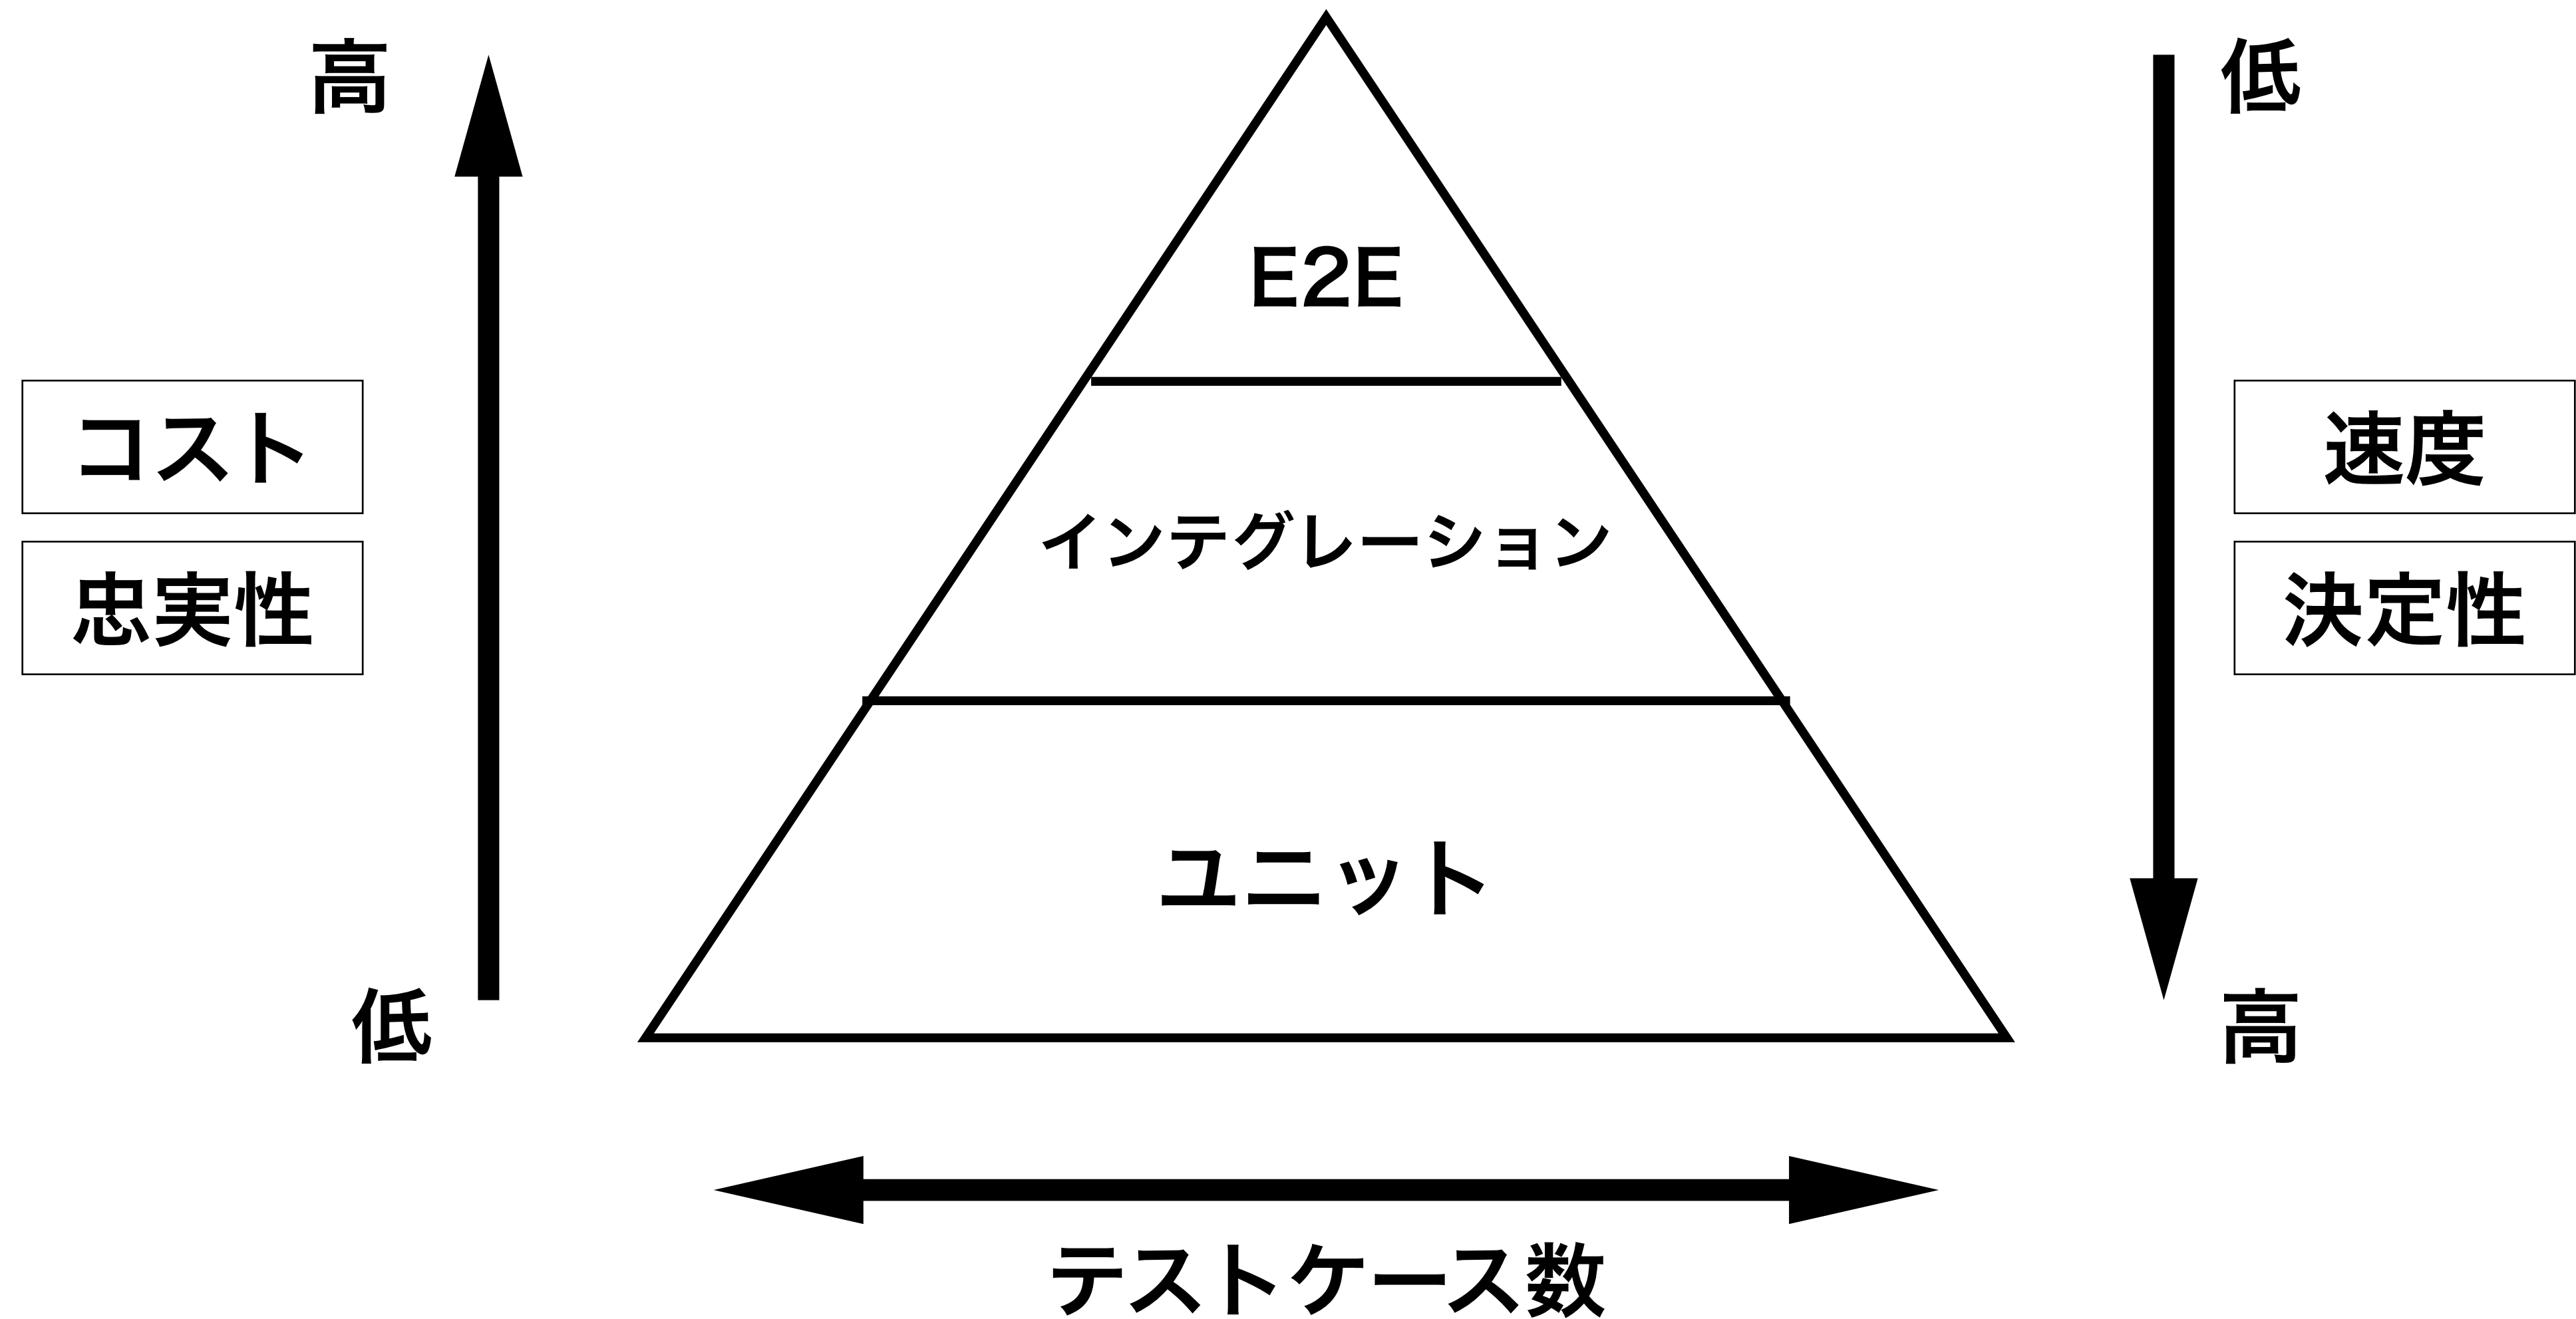
Titus Winters, Tom Manshreck, Hyrum Wright 編
竹辺 晴昭 監訳
久富木 隆一 訳

例: Google の Android 開発チームにおける Test Size

Feature	Small	Medium	Large
Network access	No	localhost only	Yes
Database	No	Yes	Yes
File system access	No	Yes	Yes
Use external systems	No	Discouraged	Yes
Multiple threads	No	Yes	Yes
Sleep statements	No	Yes	Yes
System properties	No	Yes	Yes
Time limit (seconds)	60	300	900+

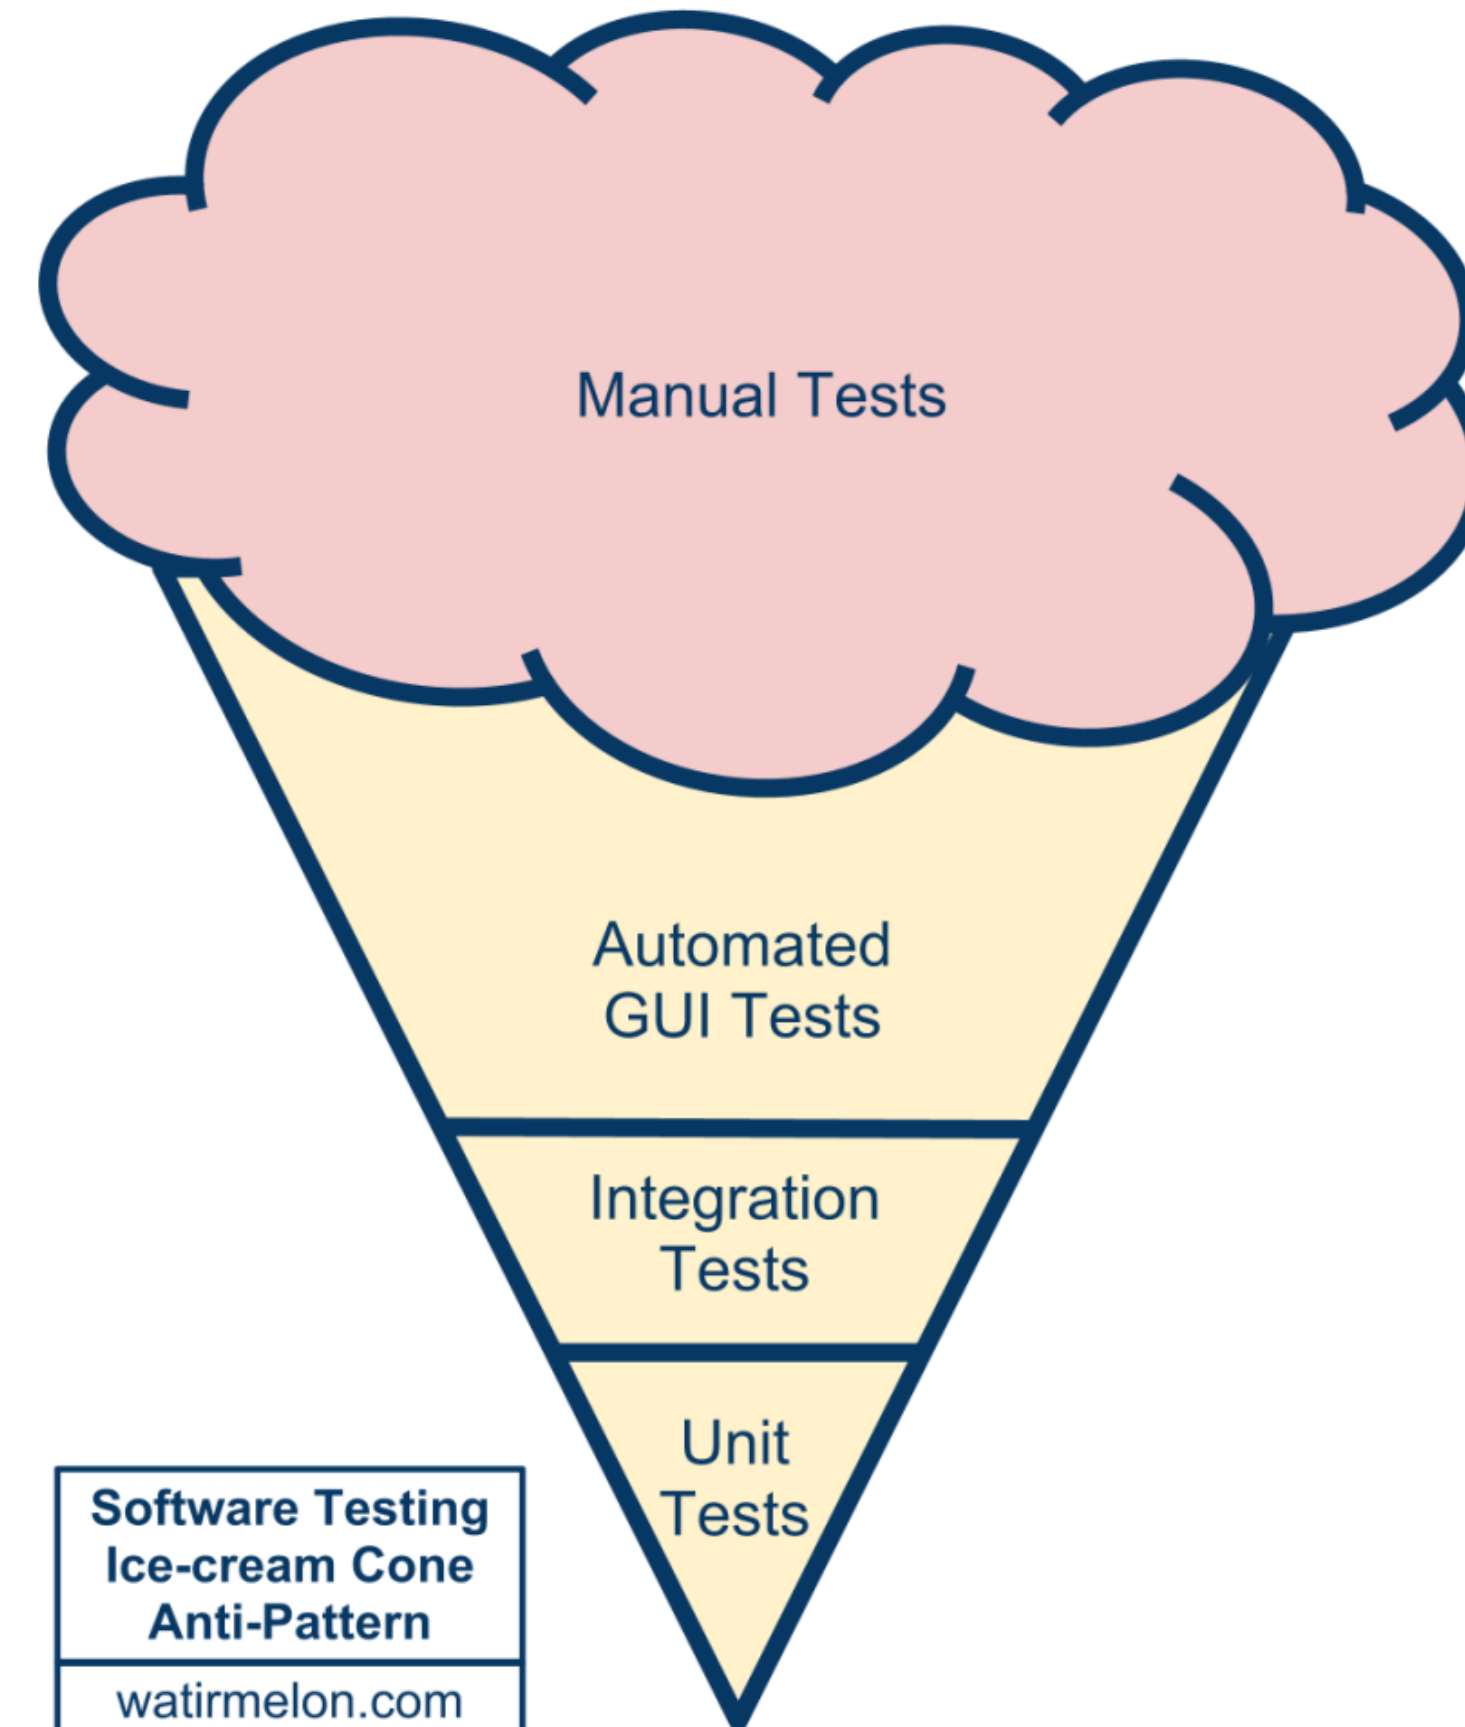
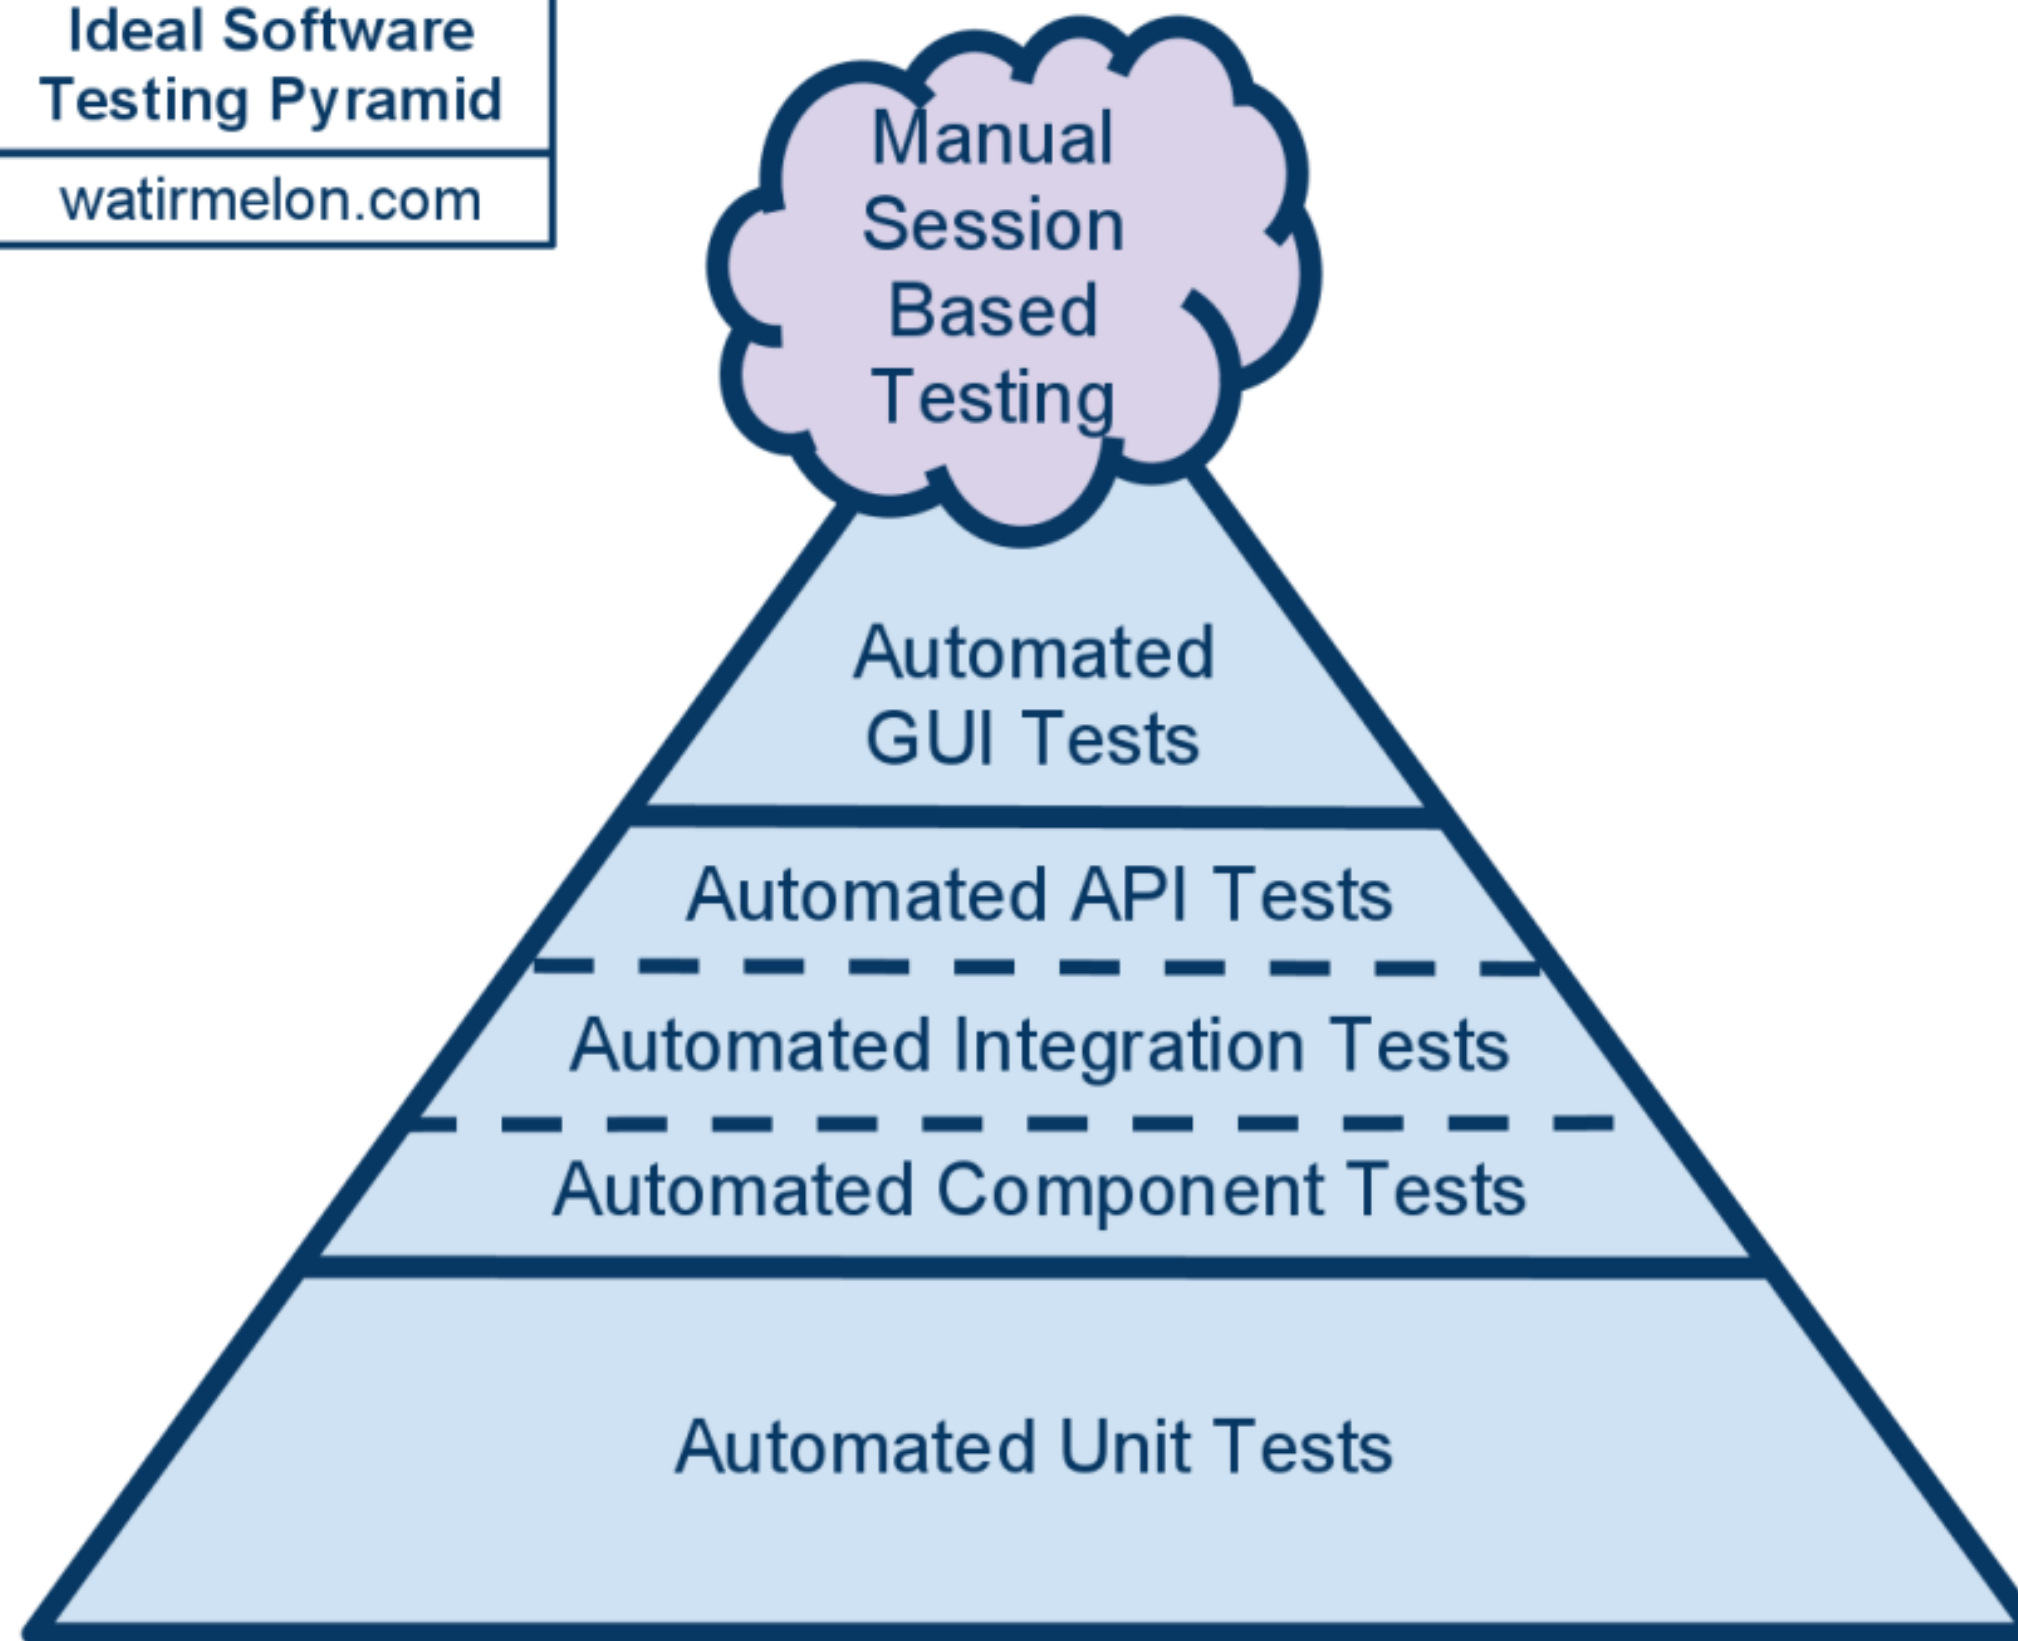
テストピラミッド:
自動テストの信頼性を
中長期的に保つ
最適なバランス

テストピラミッド





テストピラミッドとアイスクリームコーンアンチパターン

Ideal Software
Testing Pyramid
watirmelon.com




Software Testing
Ice-cream Cone
Anti-Pattern
watirmelon.com

混乱は「ユニット」「インテグレーション」の解釈のブレから生じがち




Sociable Tests



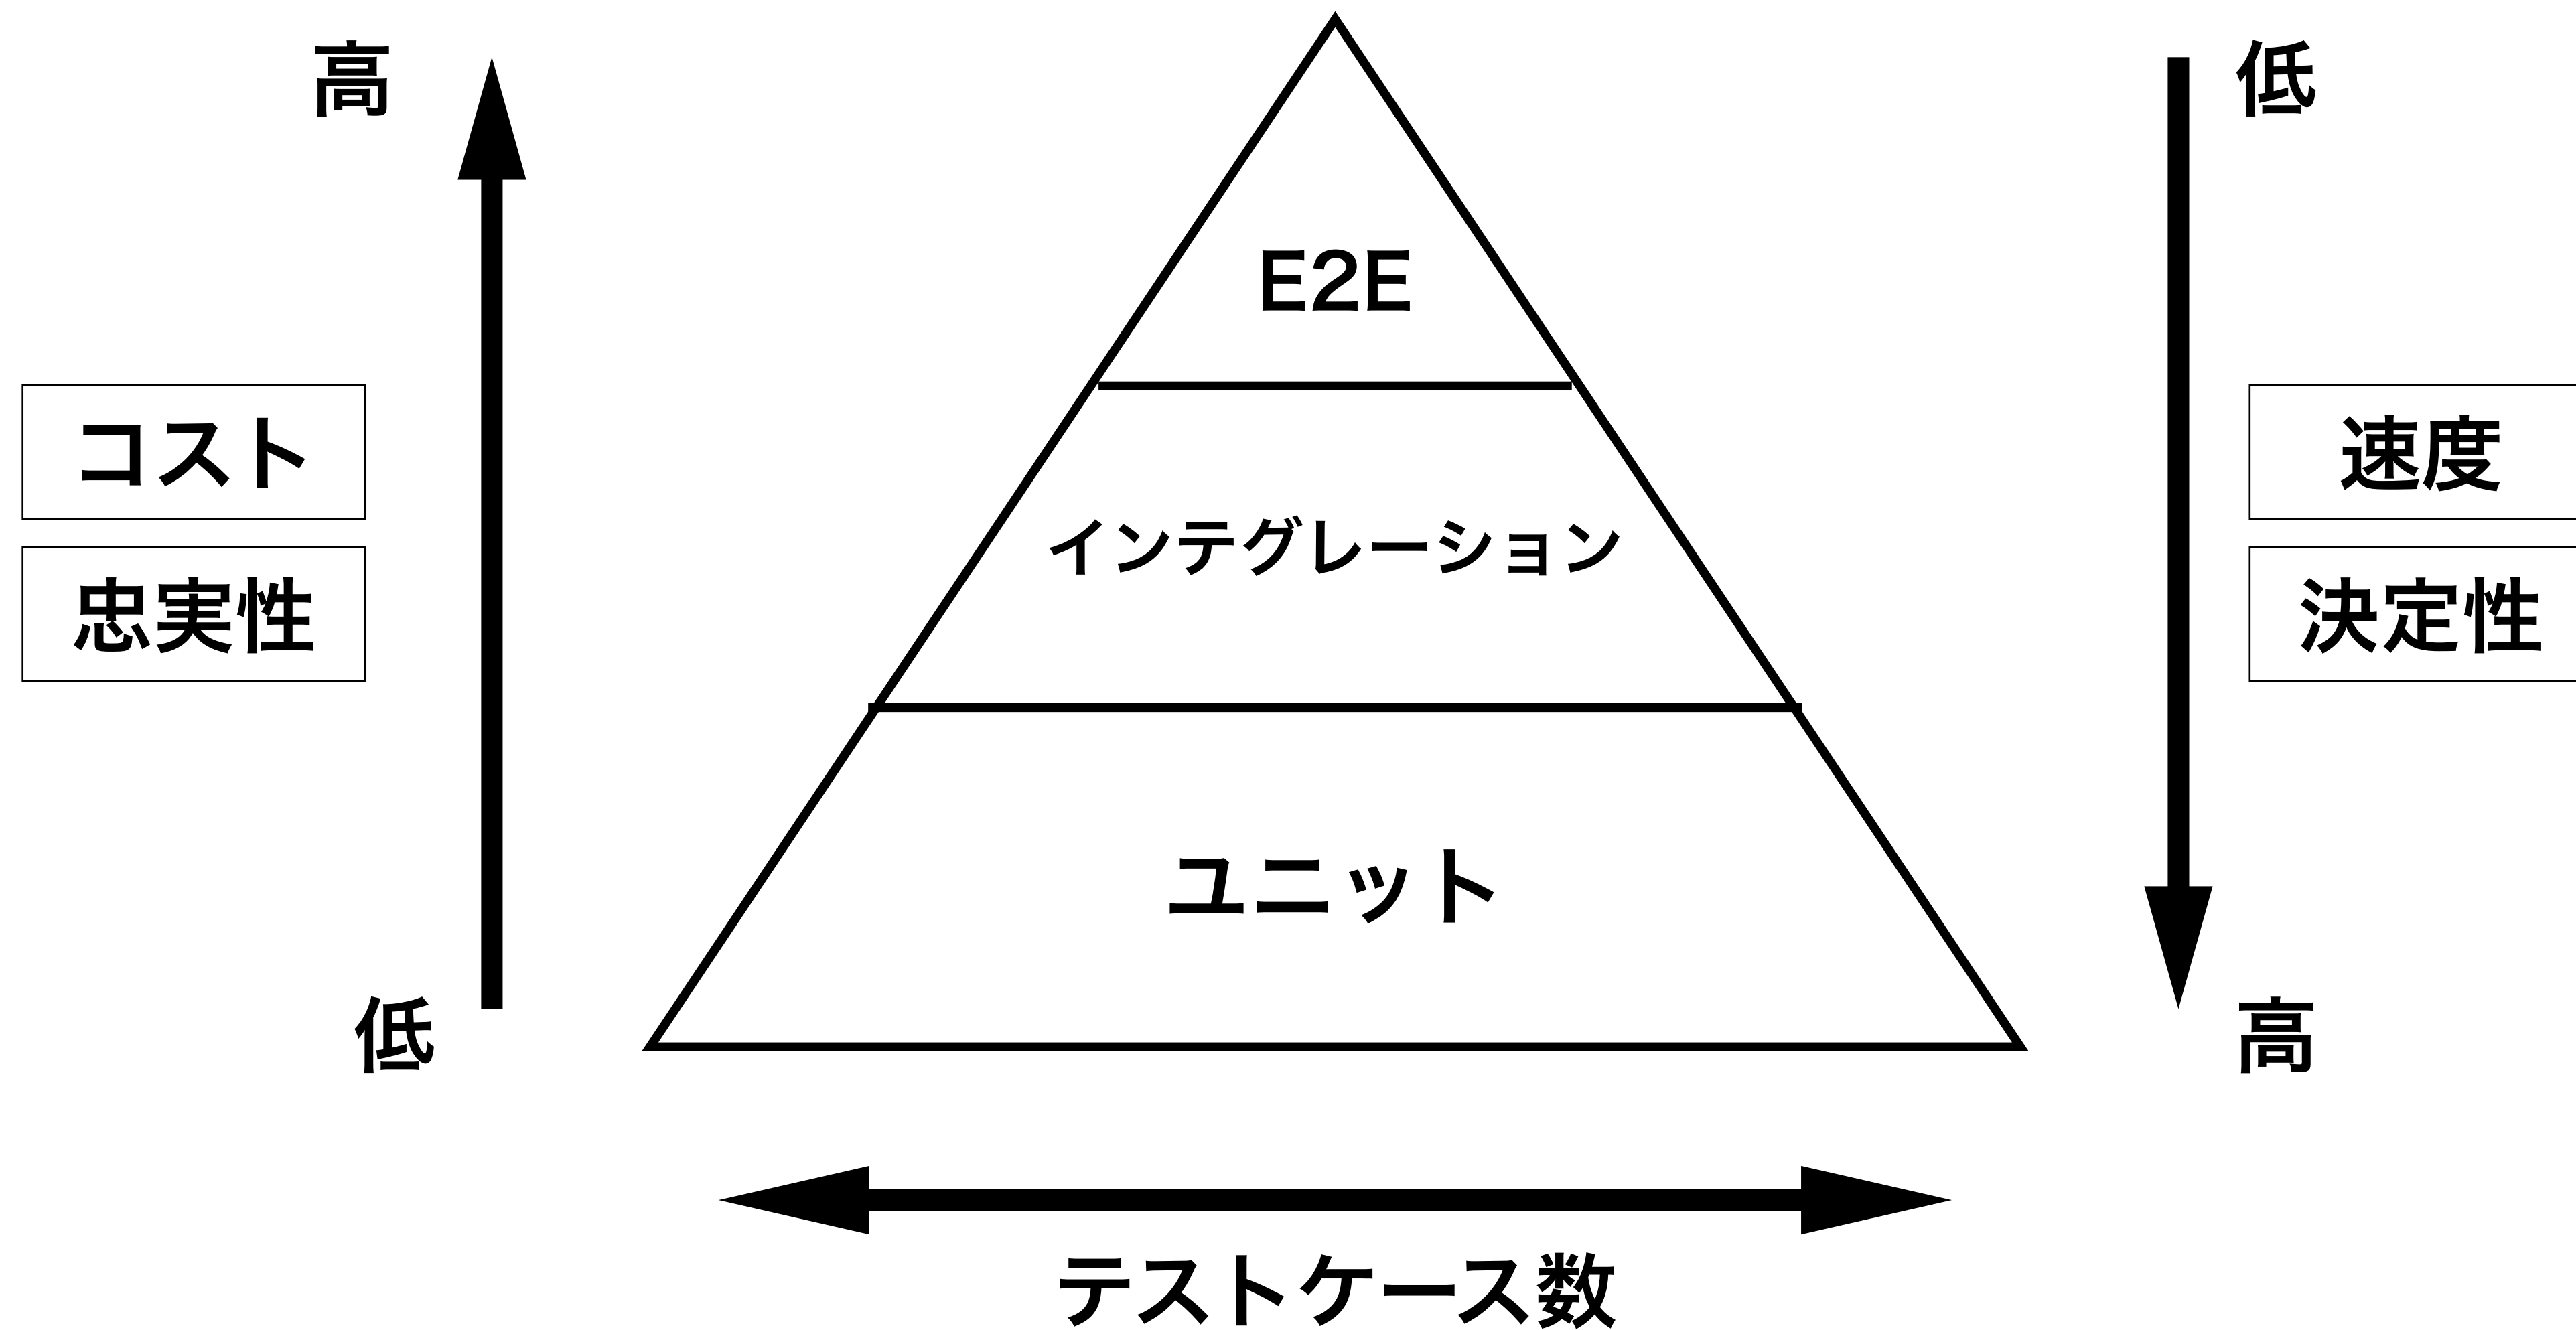
Often the tested unit relies on other units to fulfill its behavior

Solitary Tests




Some unit testers prefer to isolate the tested unit

ブレの少ないテストの分類基準は……？


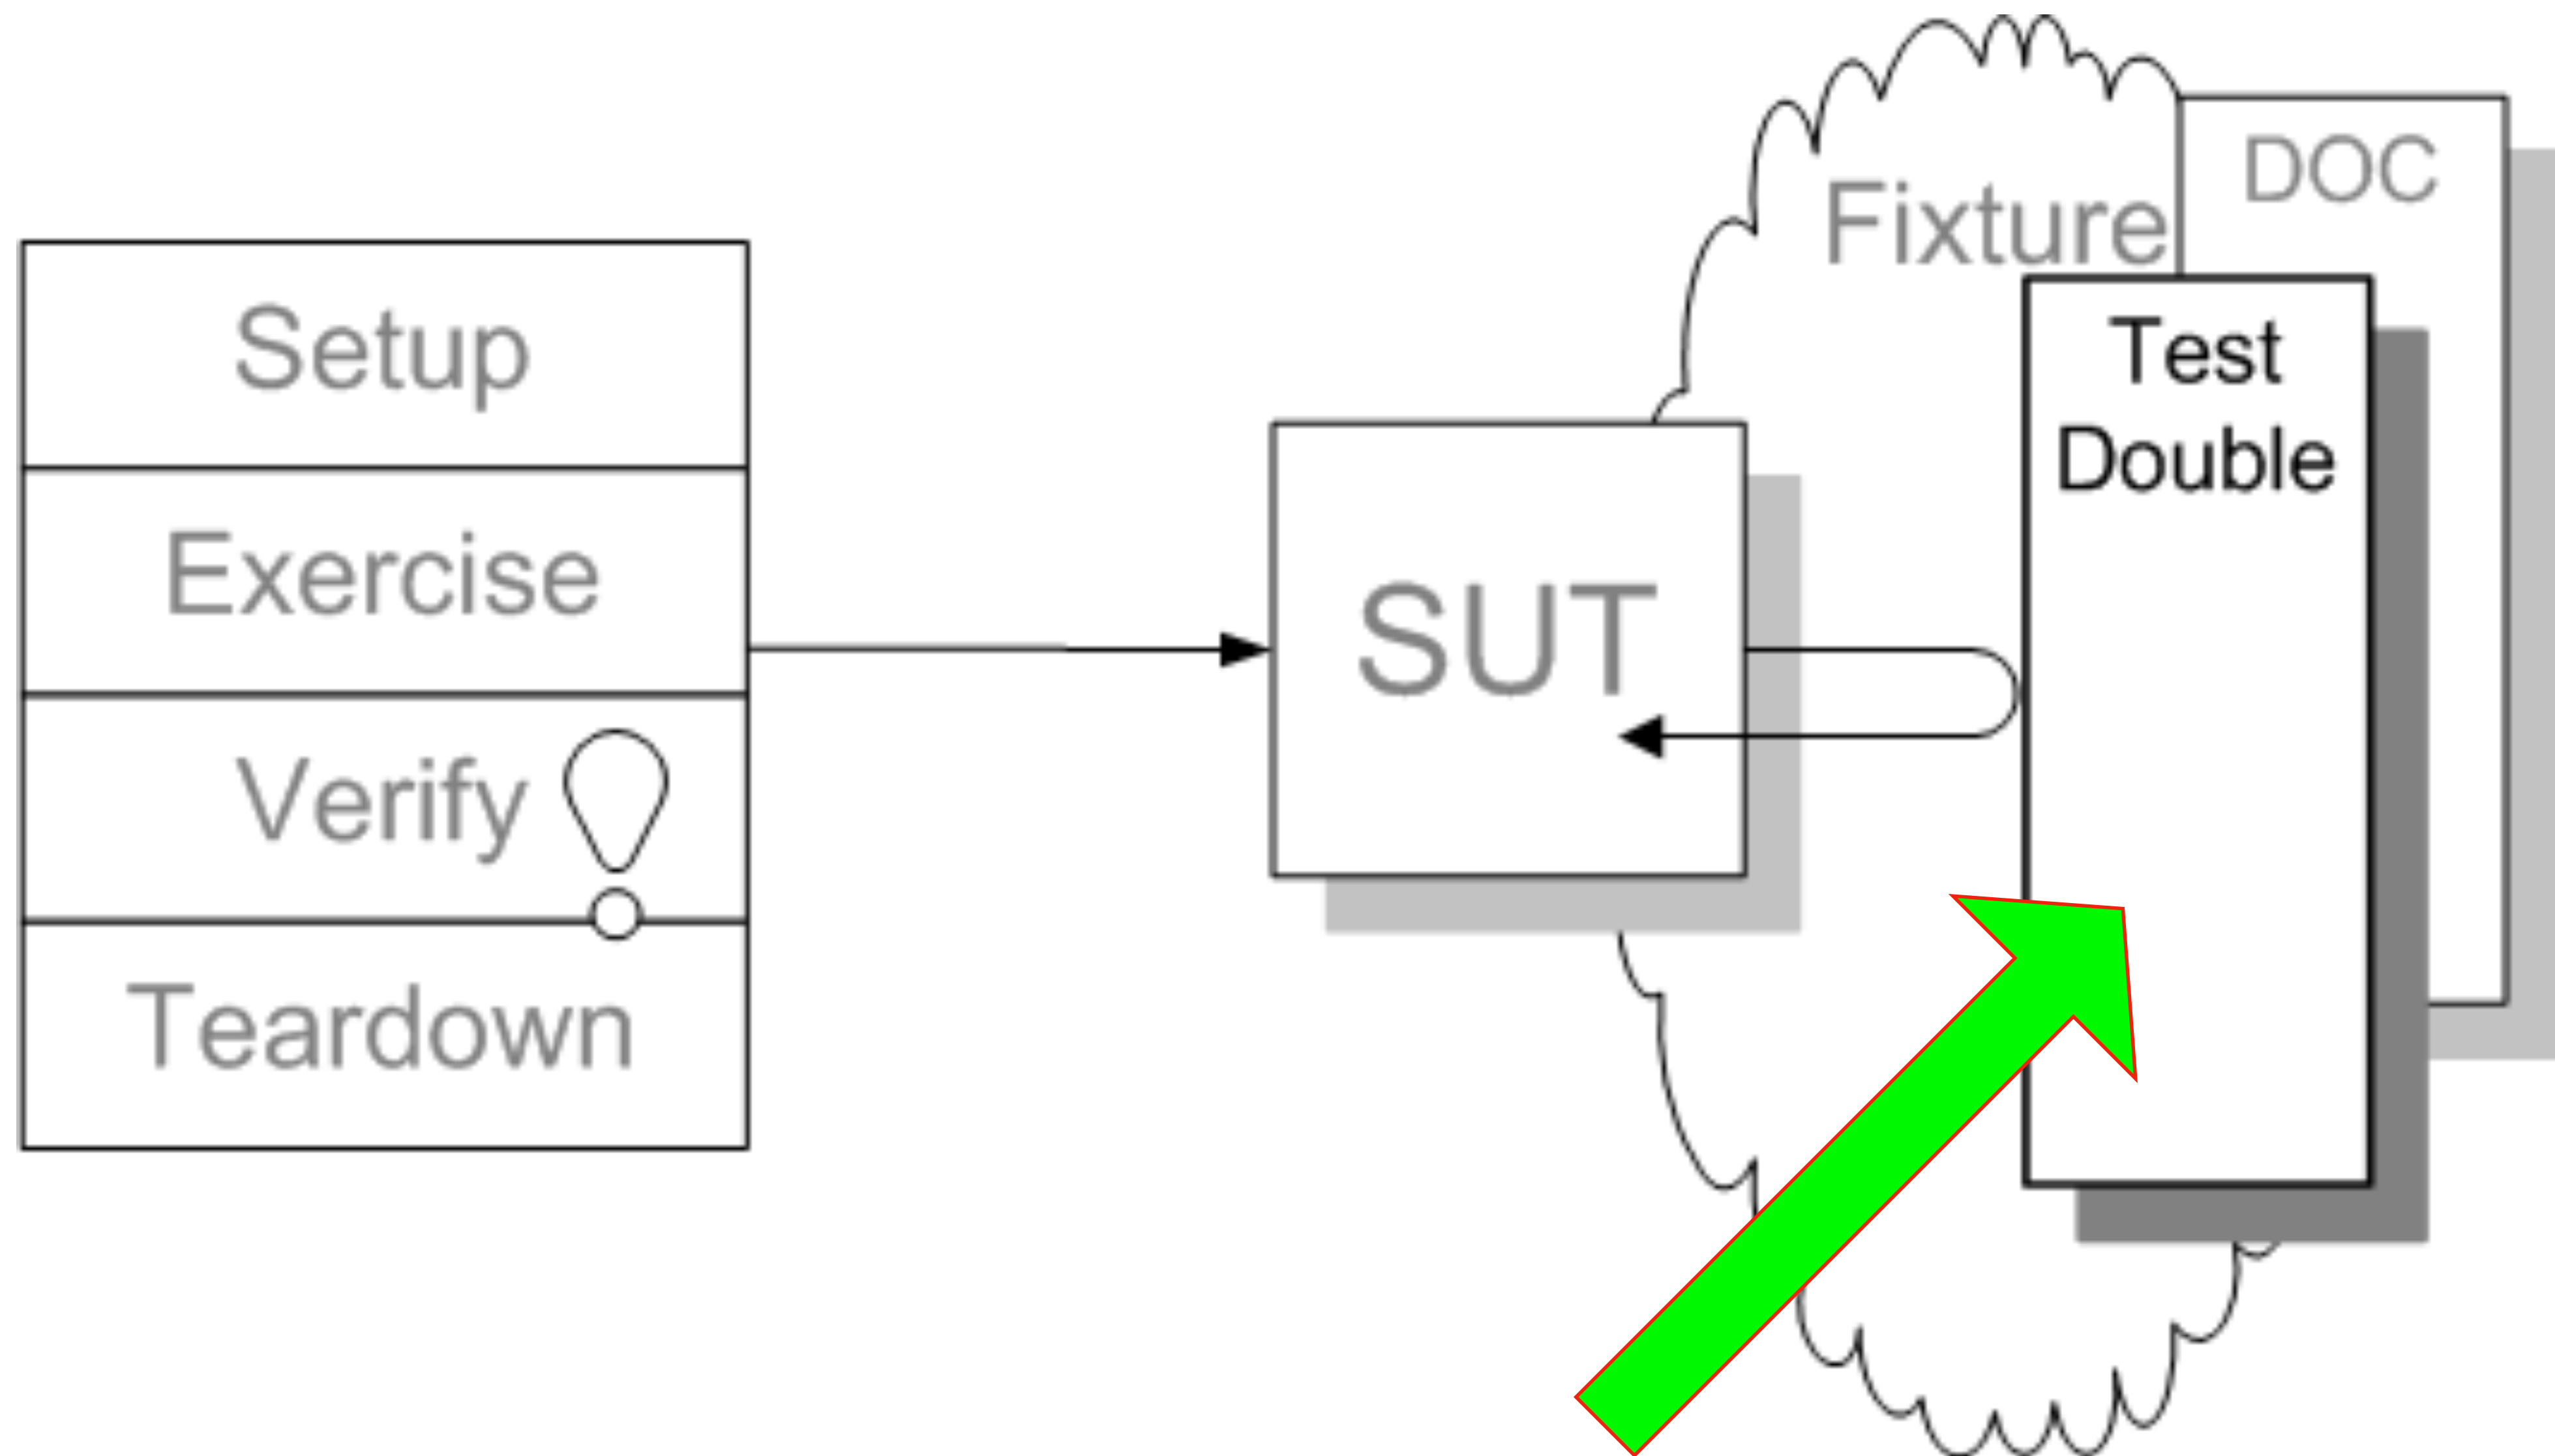


ブレの少ないテストの分類基準 → テストサイズ


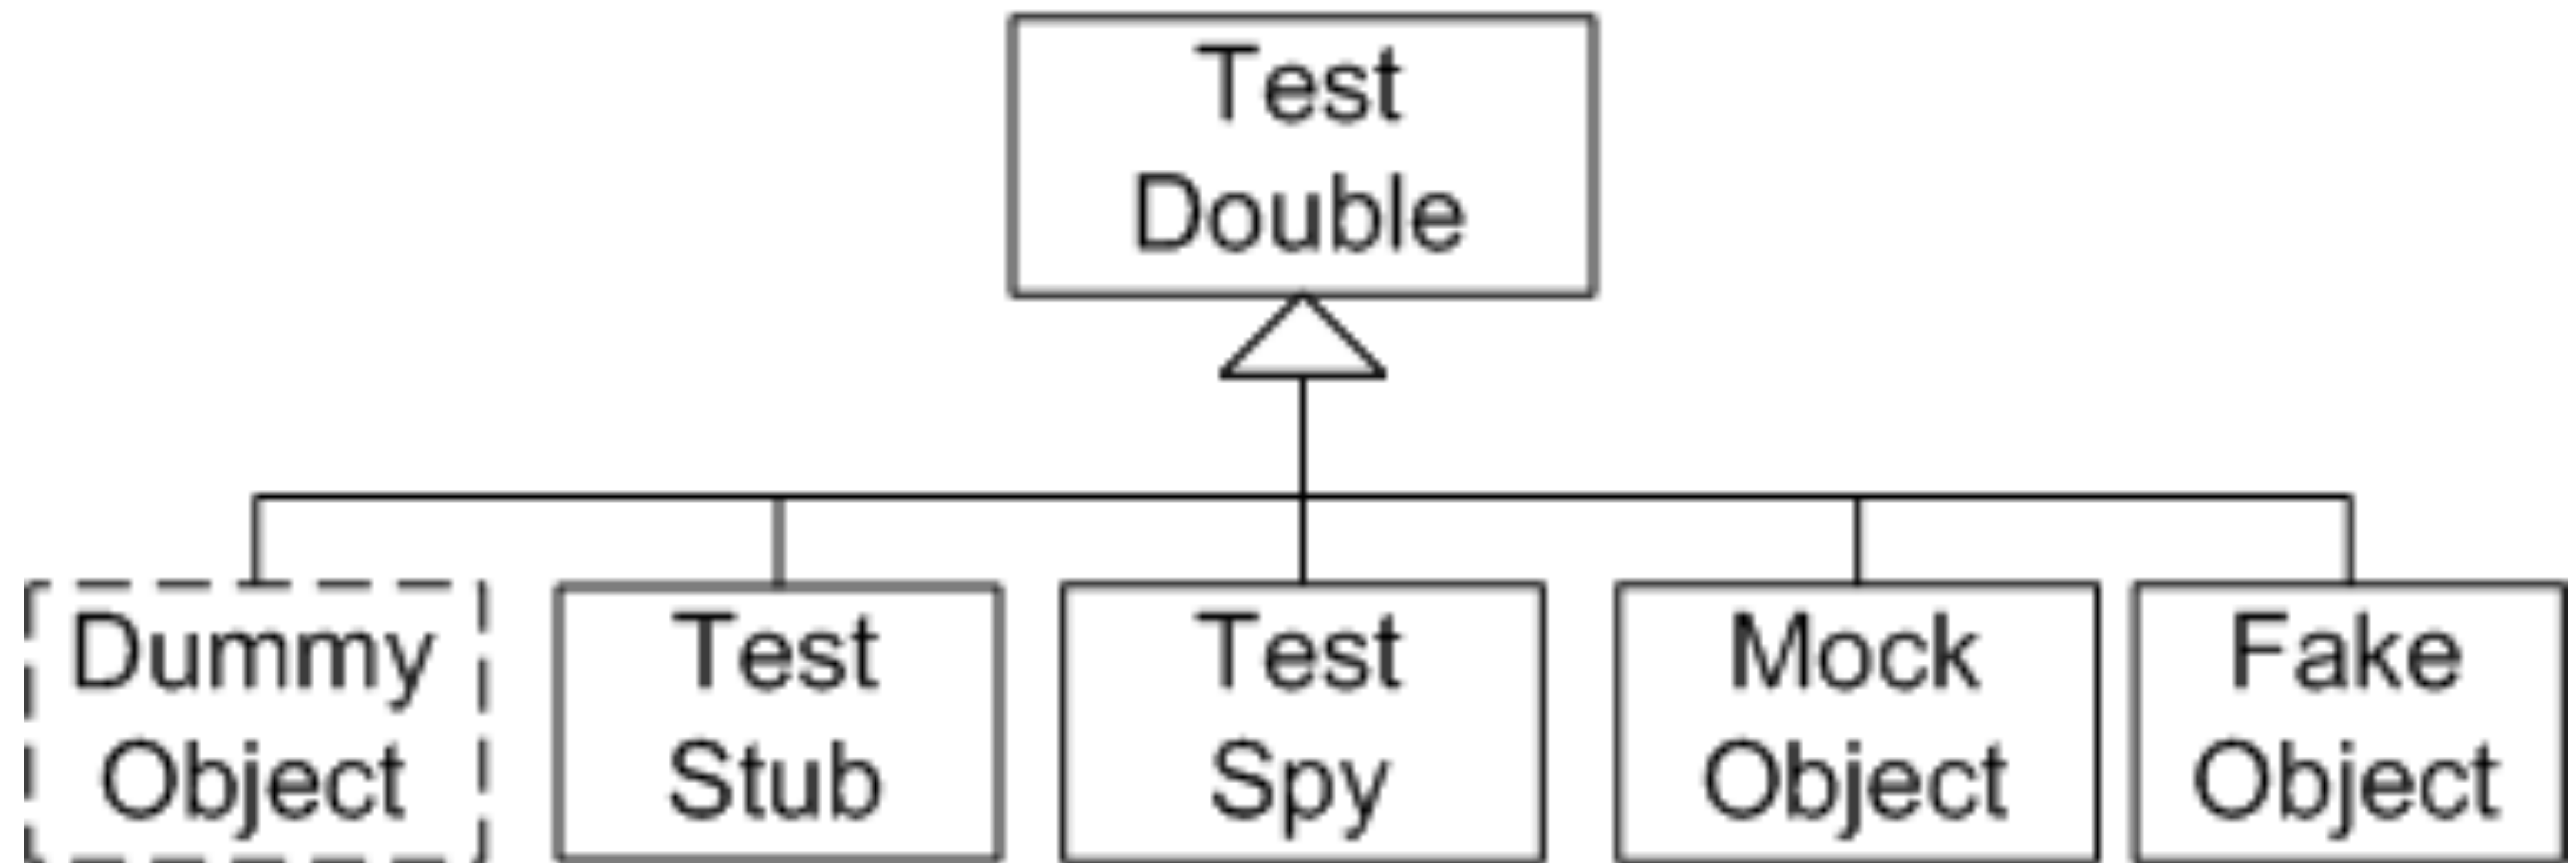


テストダブル: 忠実性と決定性の トレードオフを理解する

テストダブル: 自動テスト用の偽物



テストダブルの分類 (xUTP)



テストダブルの利点と注意点

- 利点


- そもそもテストしにくいものをテスト可能にする
- テストの速度と決定性を向上させる

- 注意点

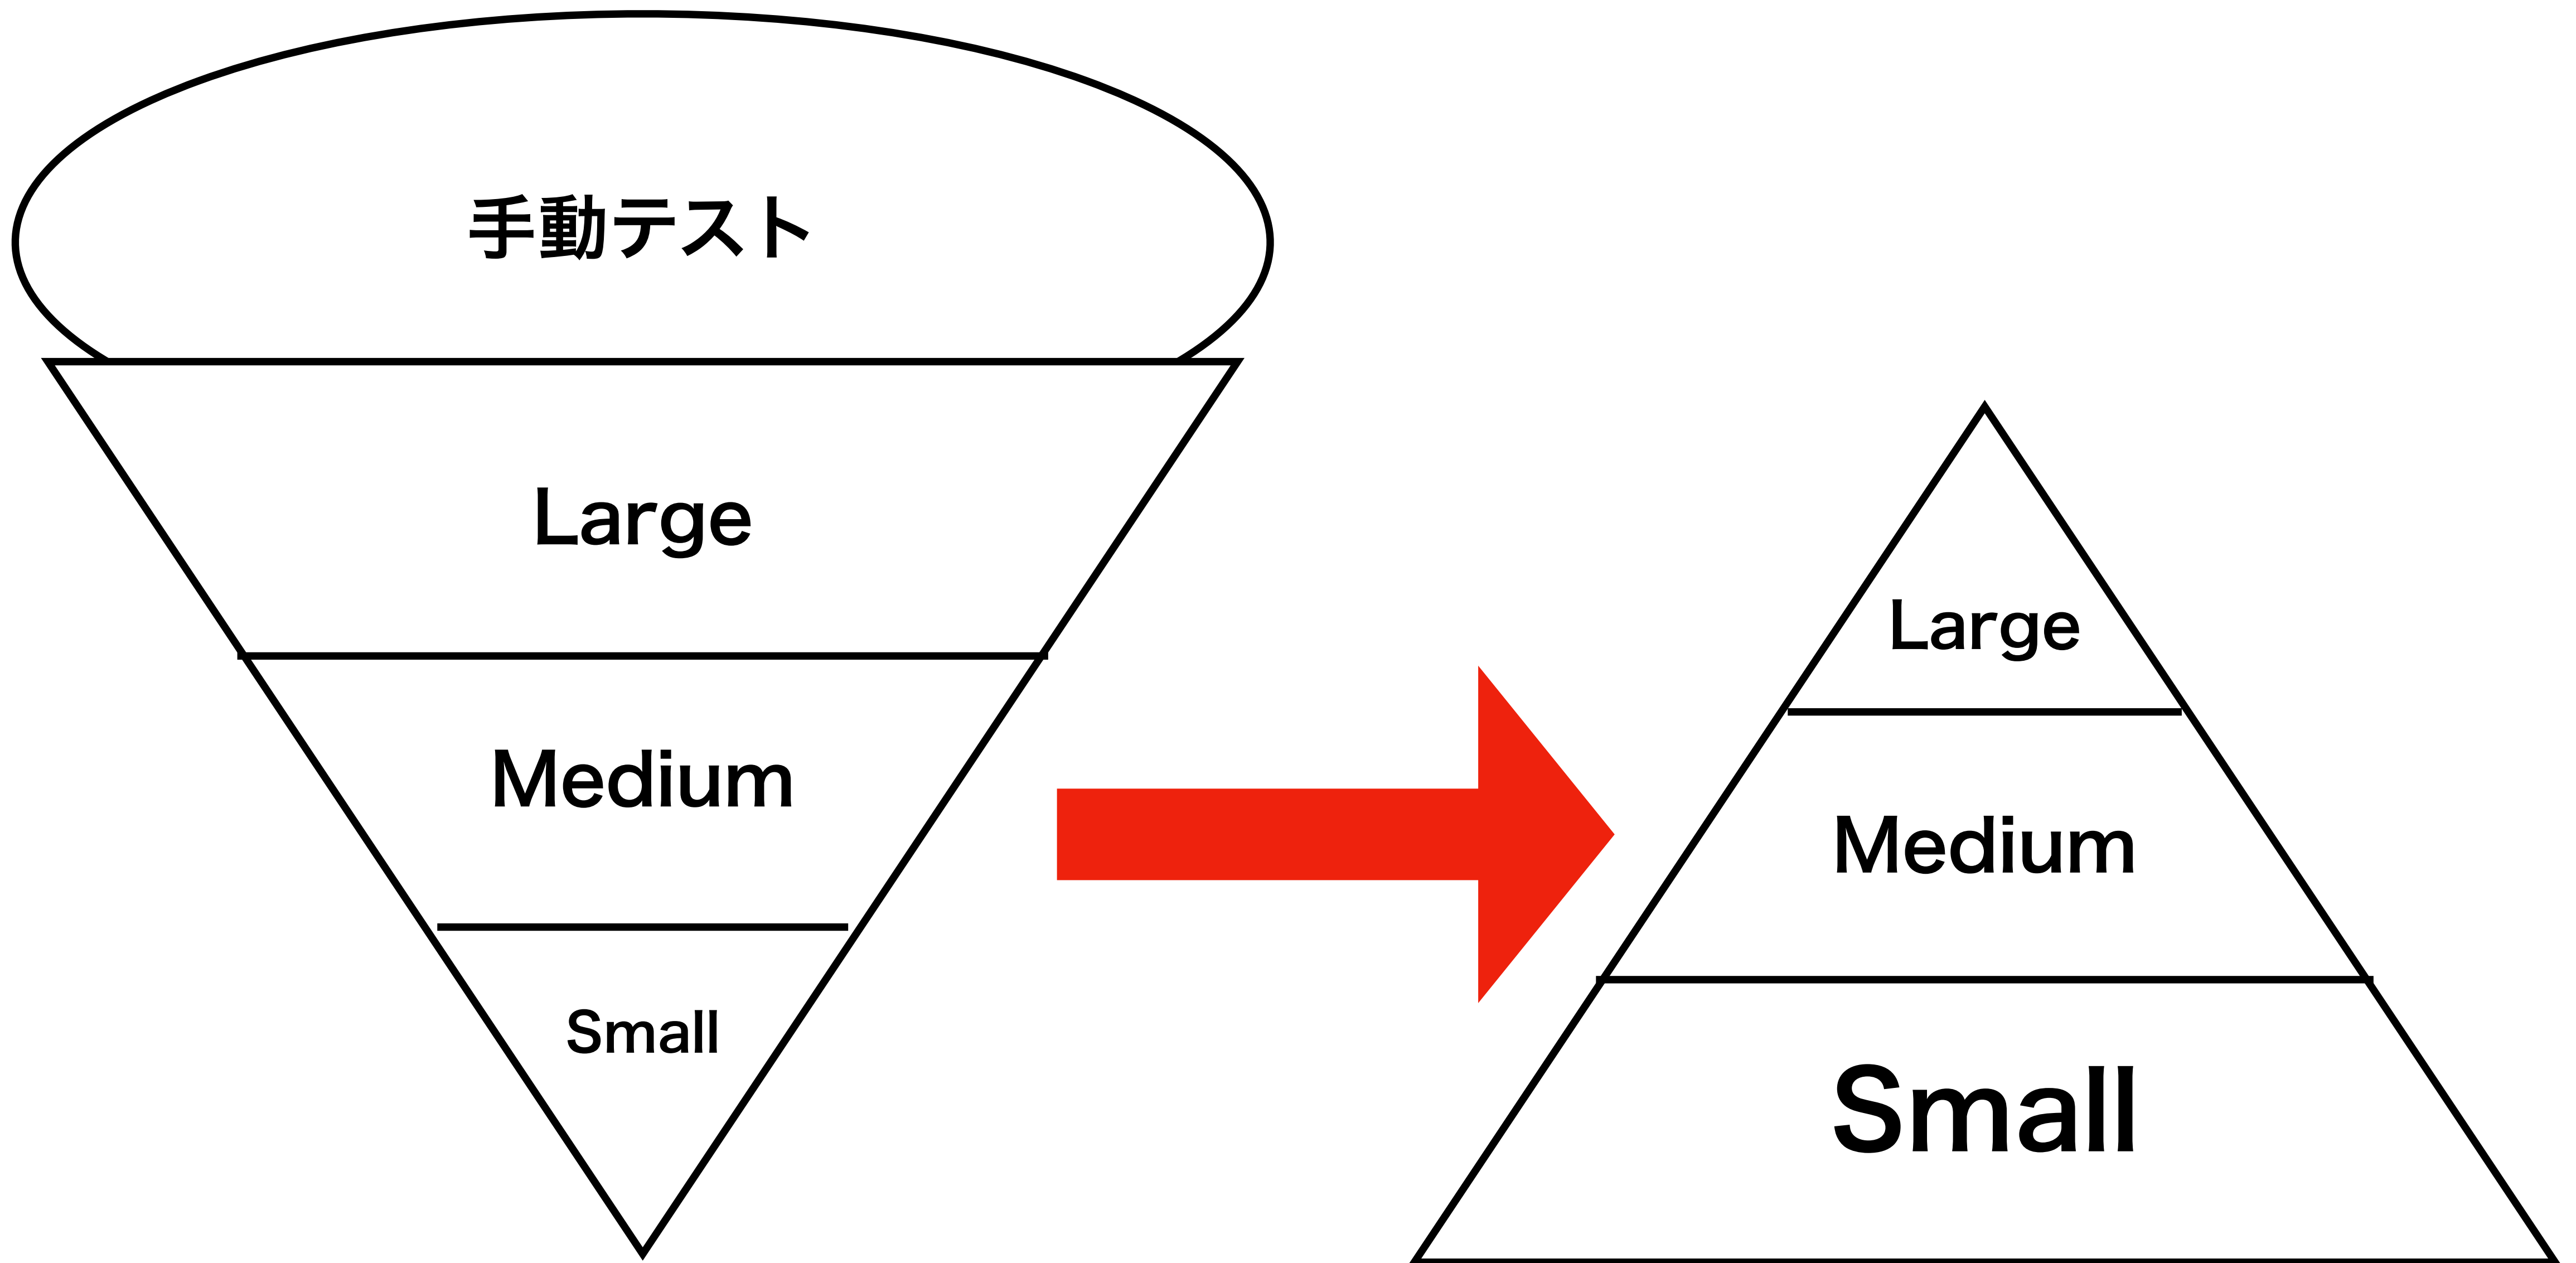
- テスト対象の実装との構造的結合が高まり、テストが脆くなり、偽陽性を招く
- 自作自演テストのリスクがあり、偽陰性を招く

サイズダウン戦術と テストピラミッド


でも、多くの現場ではアイスクリームコーンから始まる（それは悪いことではない）



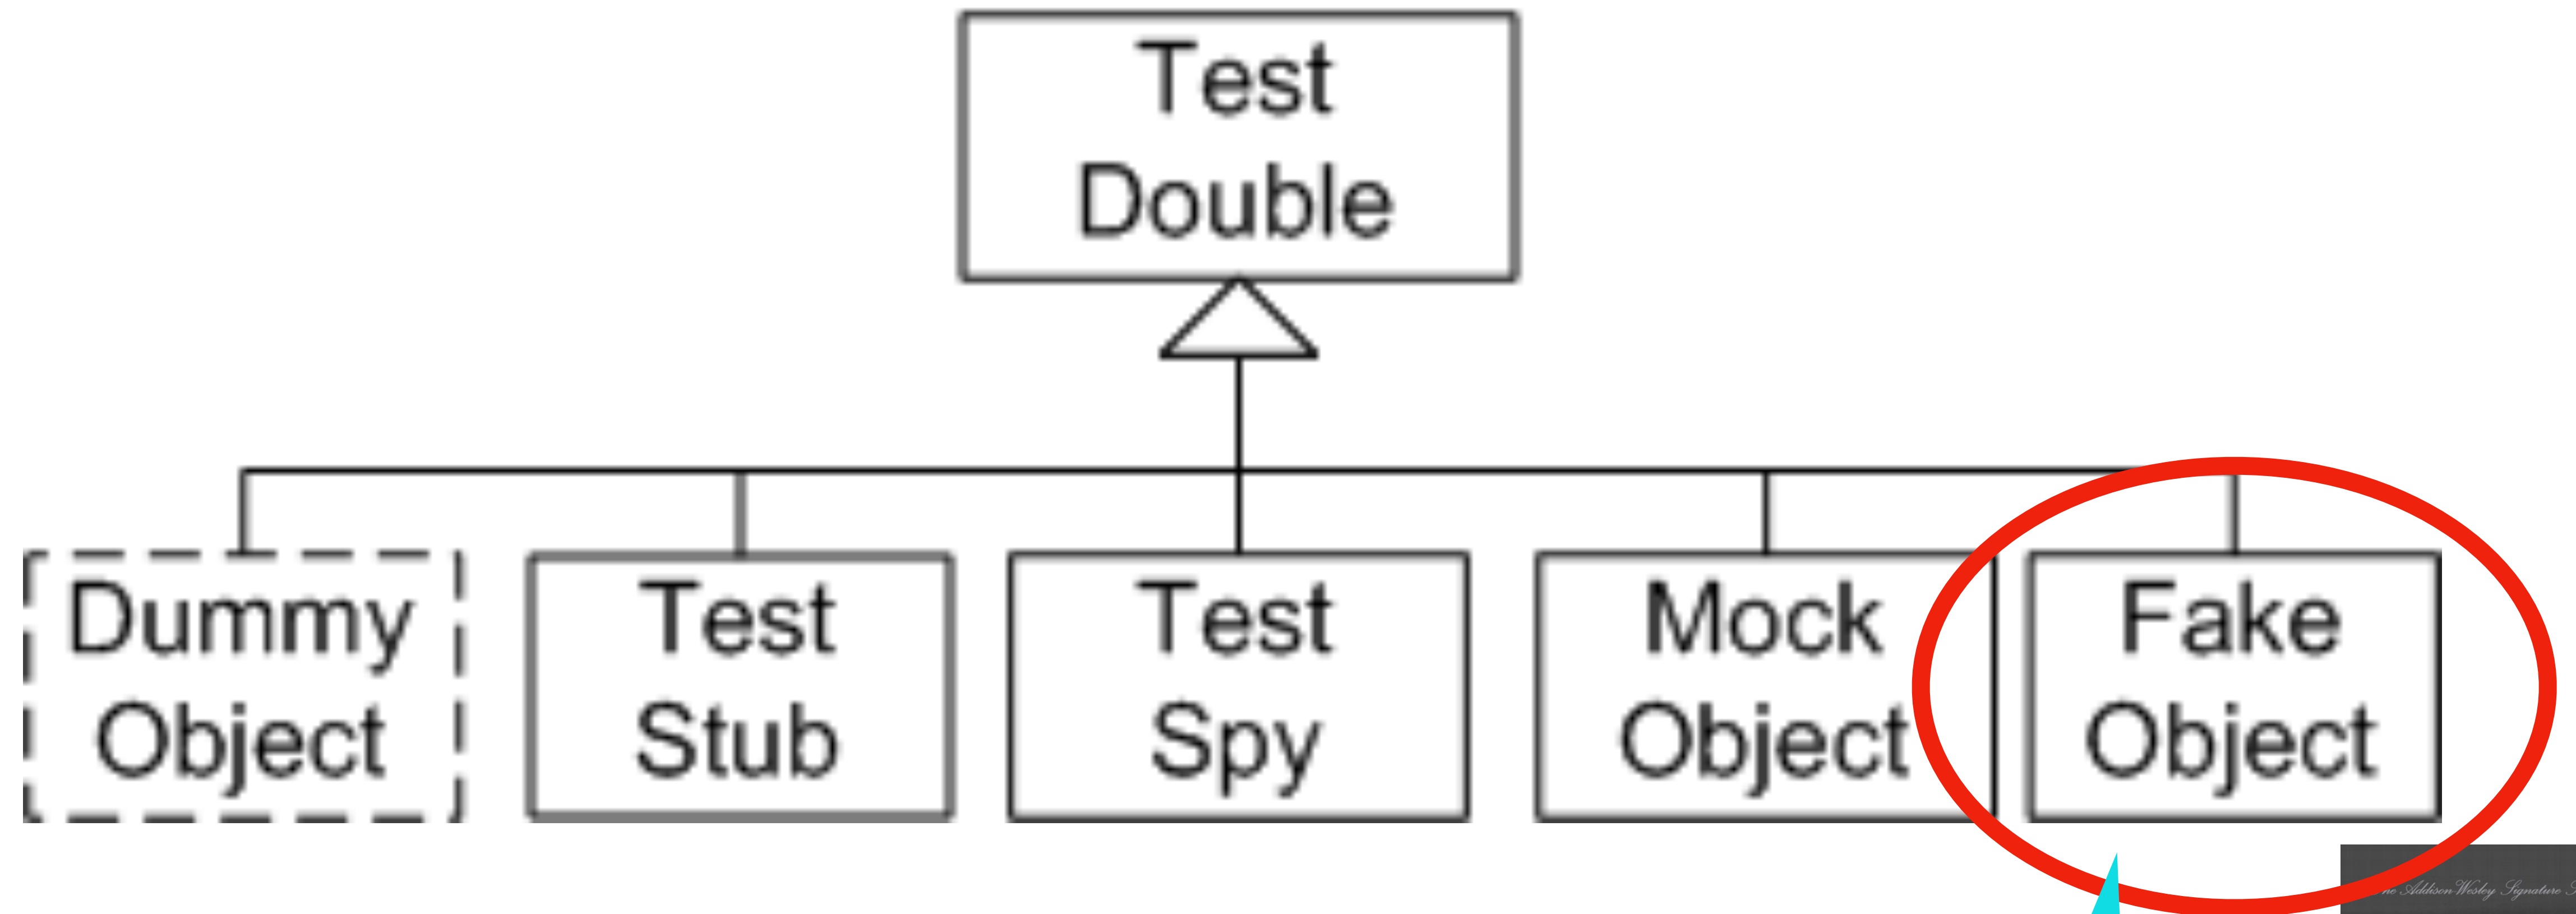
どうやってアイスクリームコーンをピラミッドにするか




Large から Medium へ




Large から Medium へ: Fake Object



Fake は自動テスト用の代替実装。
DynamoDB に対する DynamoDB local や locakstack が代表例。
コンテナで動作させられればテストサイズが Medium に収まる。






Medium から Small へ: Humble Object

*faced with a software element
that's difficult to test*



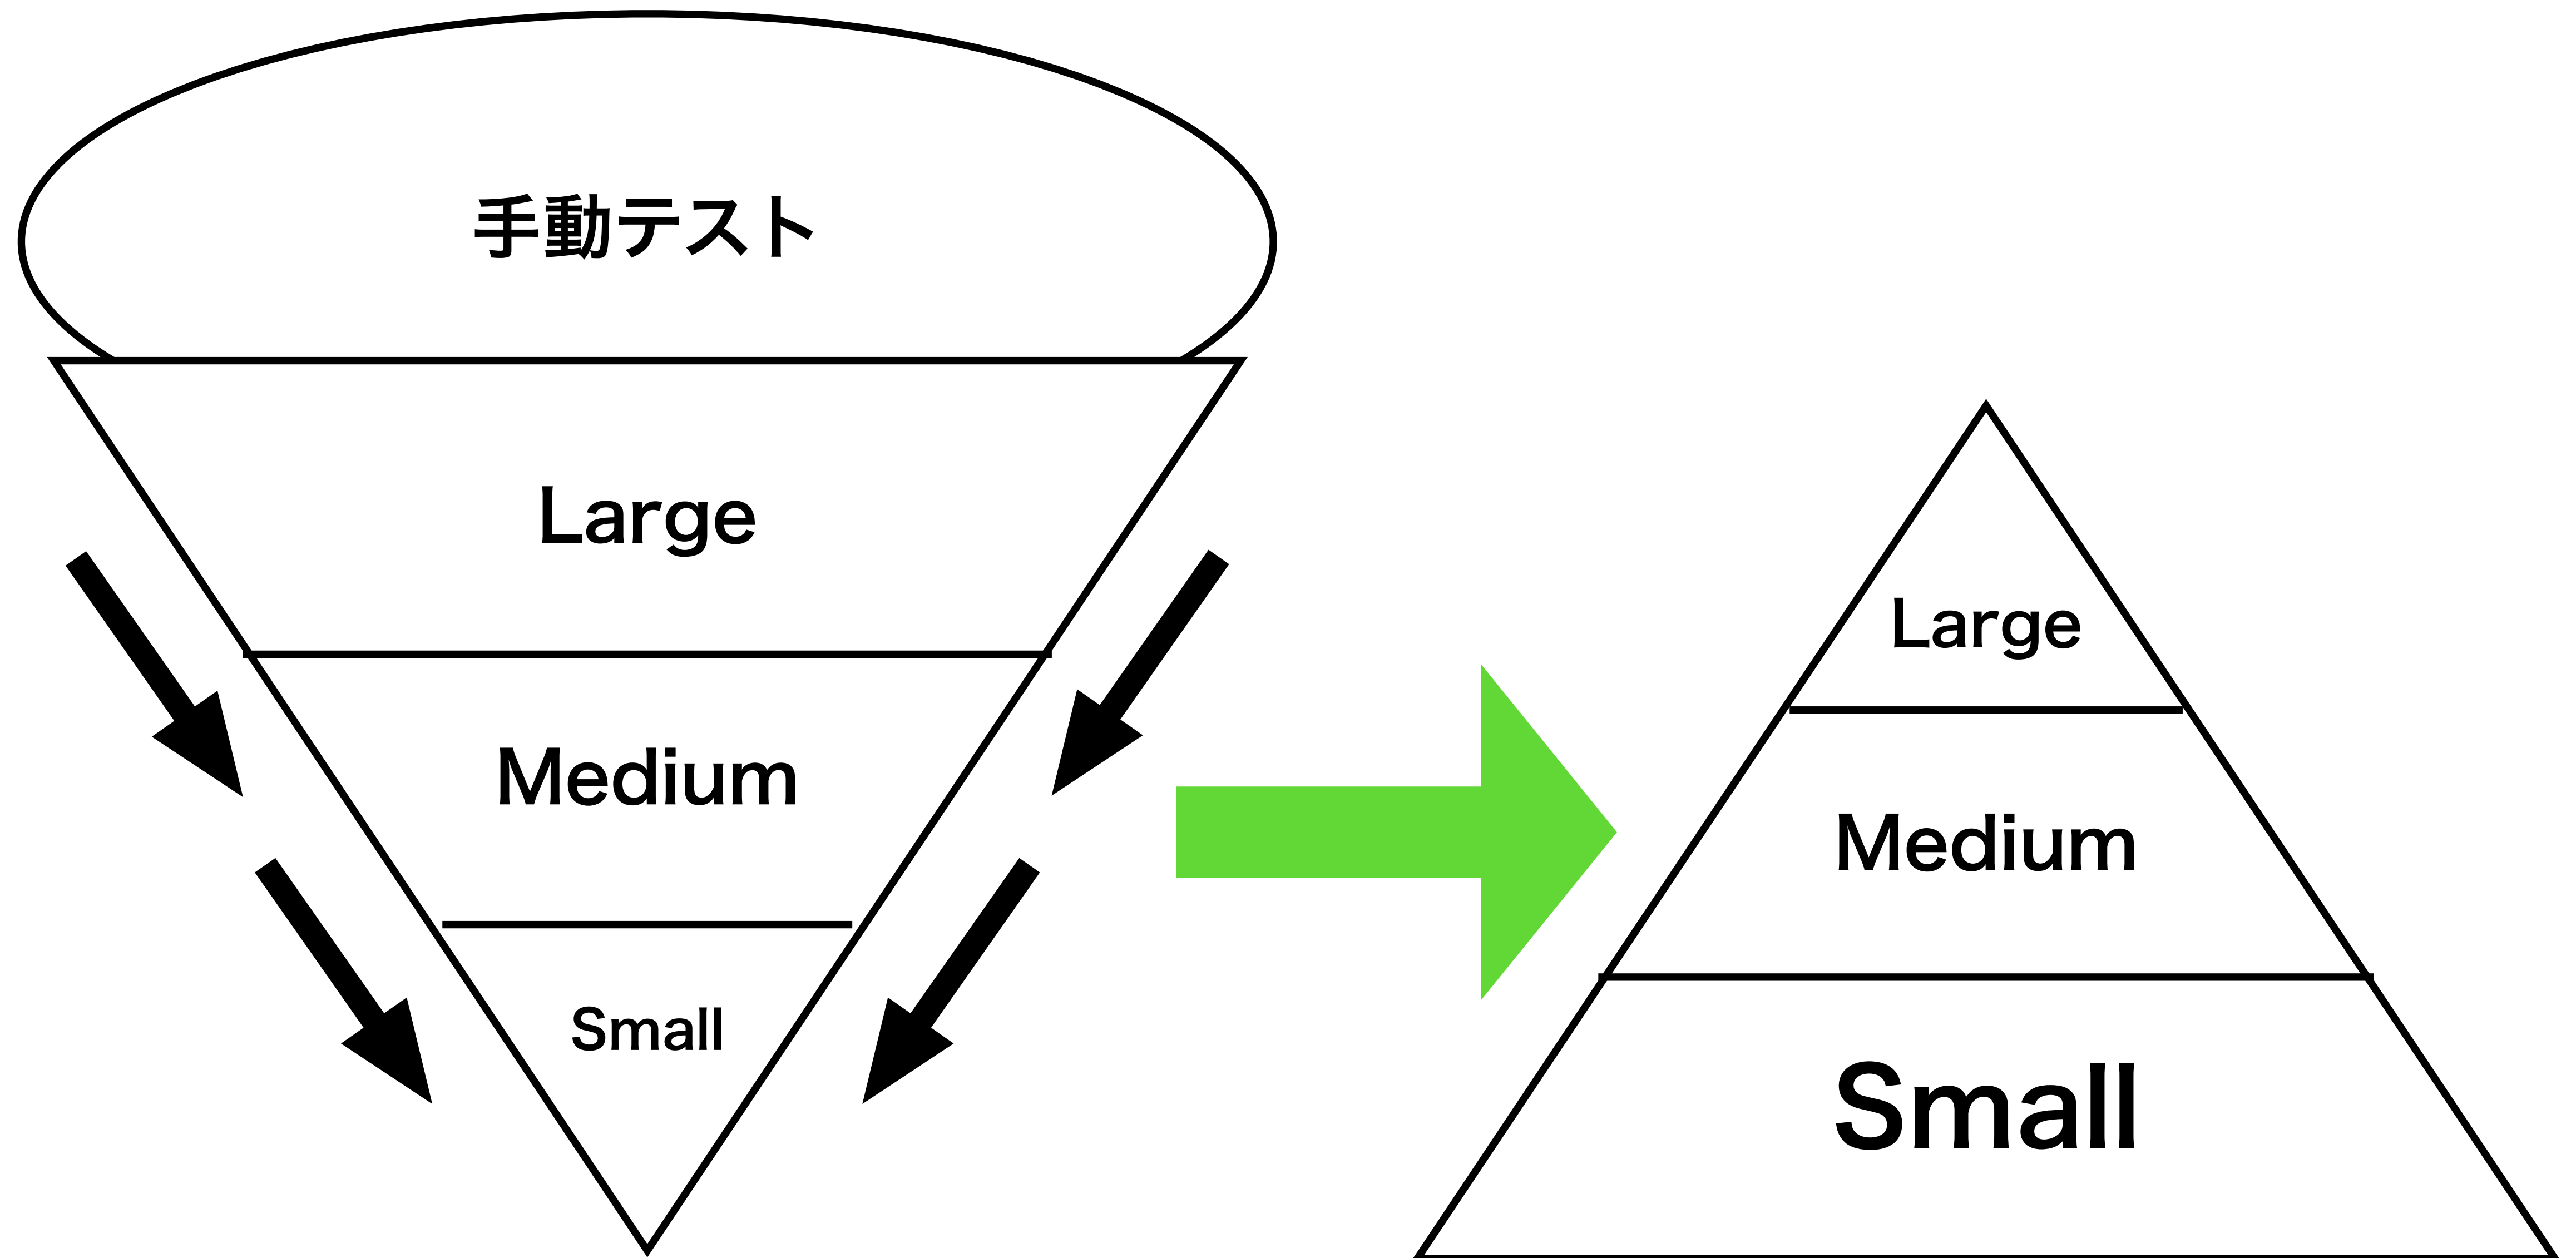
*move the logic into a separate
element that is testable, making
the original object **humble***



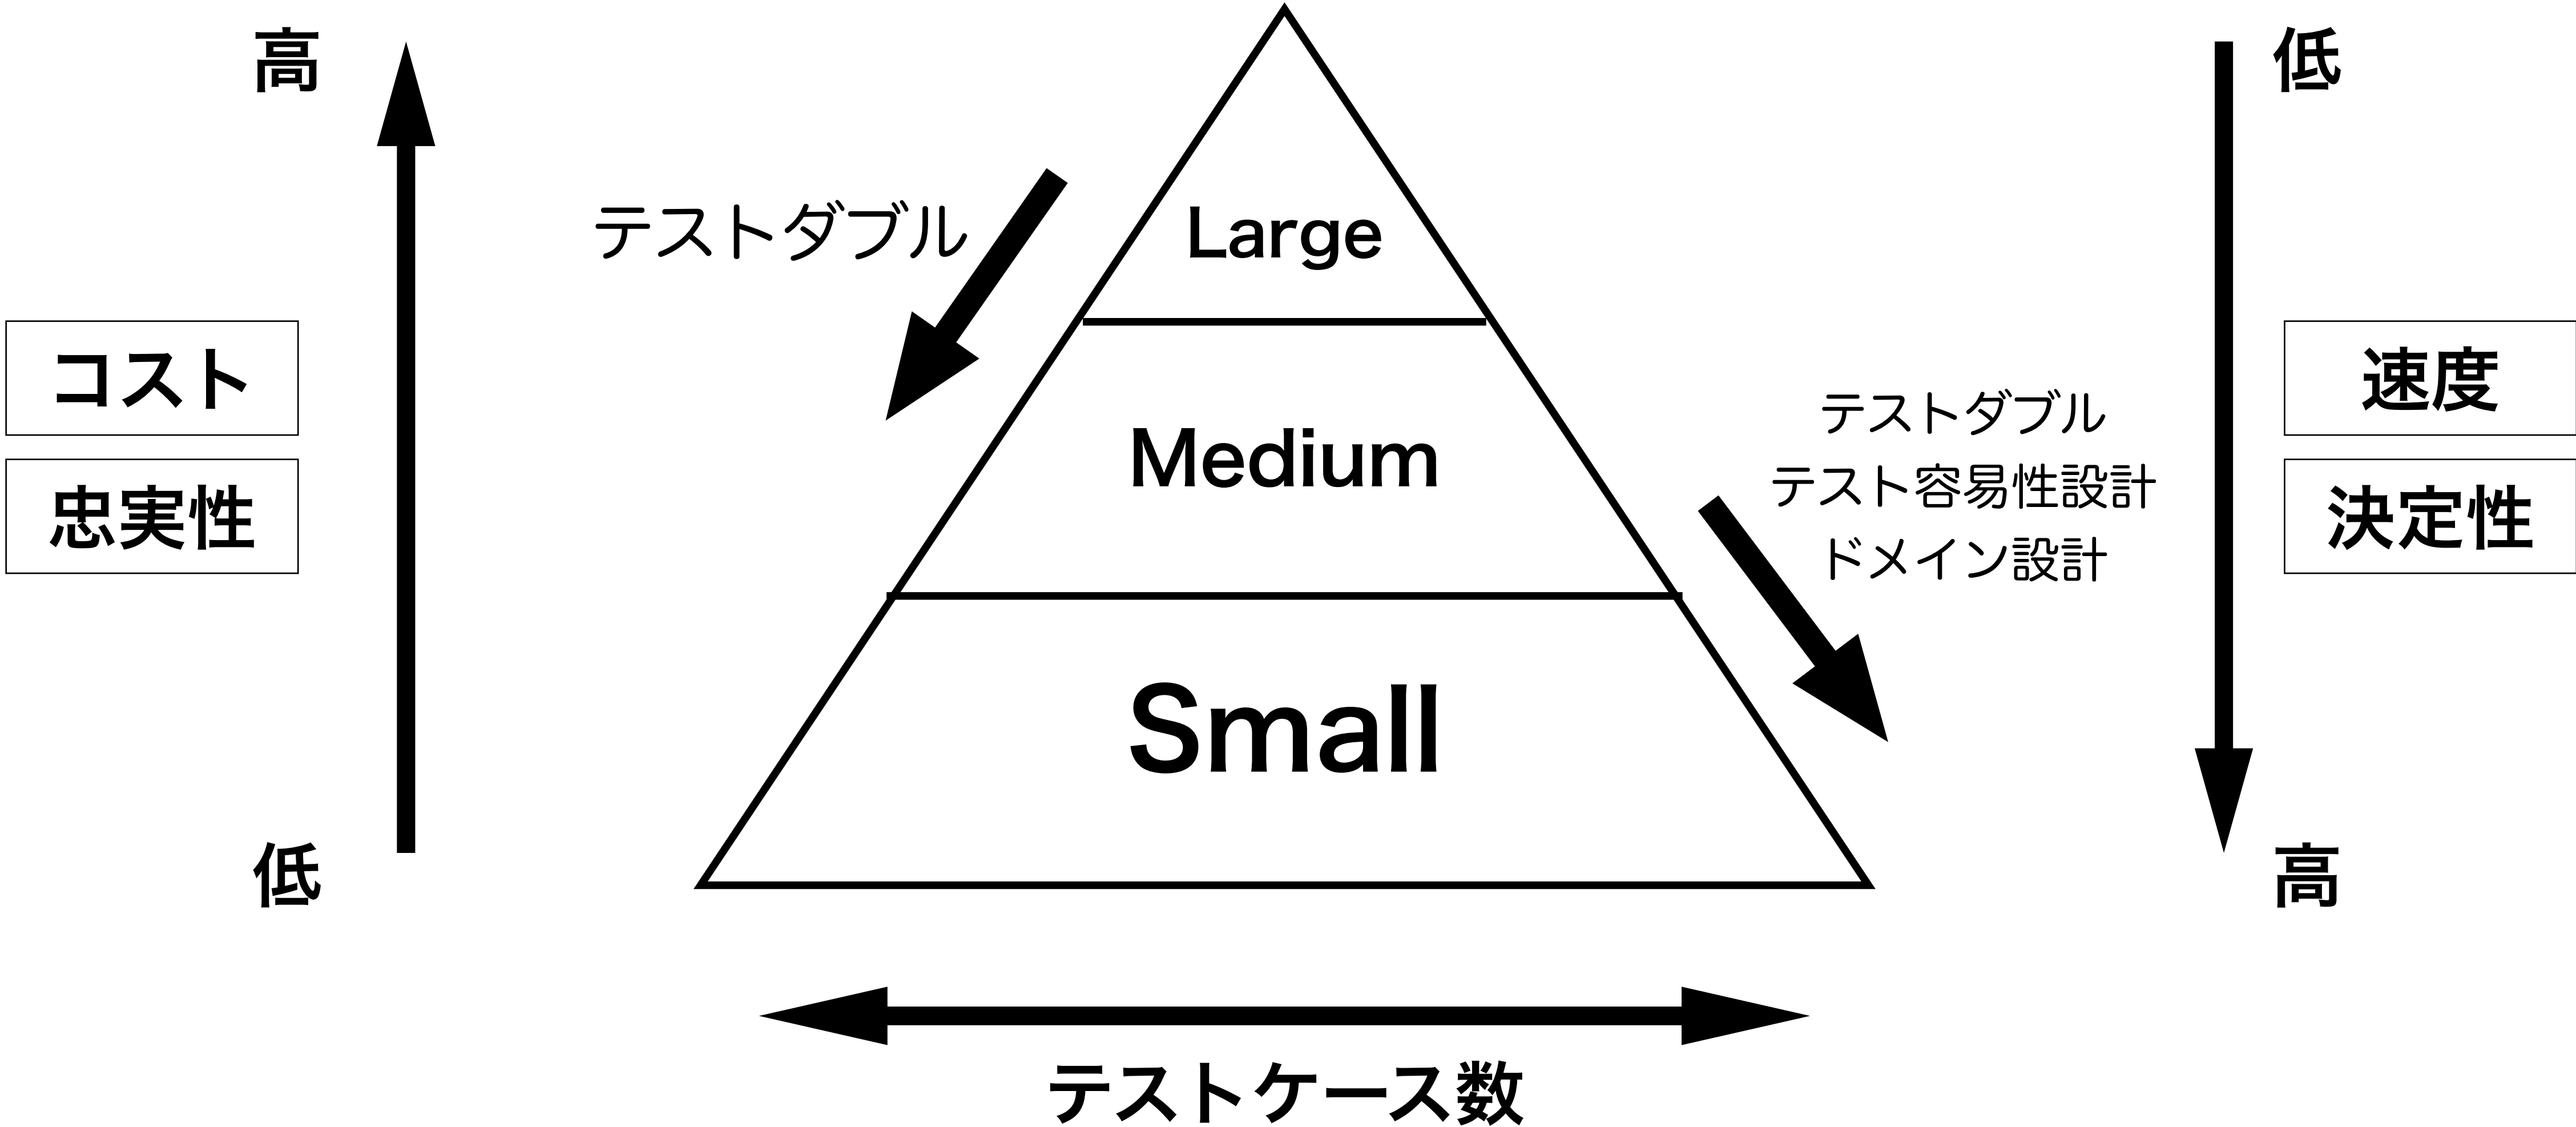
テスト容易性を下げている要素を薄く切り出し、
テスト可能範囲を広く取る基本パターン



アイスクリームコーンからピラミッドへ



テストダブルでサイズダウンして、各サイズをピラミッド型に配置し、テスト全体の信頼性を維持する



テストピラミッドとテストサイズとビルドパイプライン

ci.yml

on: pull_request

メモリ内で動く Small Test
できるだけこの比率を高めたい

ビルド後のイメージや DB 等を組み合わせた
Medium Test

✓ small-test / run-small-tests 17s

✓ build / build-images-then-... 31s

✓ medium-test / run-mediu... 26s

✓ deploy-staging / deploy-c... 39s

✓ infra-staging / provisionin... 14s

✓ large-test / run-large-test 1m 2s

✓ migrate-db-staging / migr... 23s

実システムに近い構成の
Large Test
(なので遅くて不安定)

large

medium

small



Agenda



信頼性の高い

実行結果に

短い時間で到達する




状態を保つ

信頼性の高い自動テストを備えること


テストに合格したソフトウェアであればリリース可能、不合格であれば重大な不具合がある、とチームが確信できるようなテストを実施していること

1. 誤検知（偽陽性: false positive）や見逃し（偽陰性: false negative）が多く、信頼性に欠けるテストスイートがあまりに多すぎる
2. 信頼度の高いテストスイートを作り上げる継続的な努力と投資は価値がある

『LeanとDevOpsの科学』 p.65（※訳を一部変更）



2. 信頼度の高いテストスイートを作り上げる継続的な努力と投資は価値がある



偽陽性と偽陰性のパターン

- 偽陽性
 - 脆いテスト (brittle test, fragile test)
 - 信頼不能テスト (flaky test)
- 偽陰性
 - 空振り
 - カバレッジ不足、テスト不足
 - 自作自演

テストの信頼不能性が増加の一途をたどるようなら、生産性を失うよりもっとまずいことを経験することになるだろう。つまり、**テストへの信頼の喪失**である。チームがテストスイートへの信頼を失うまでに、そう多くの信頼不能テストの調査は要しない。テストへの信頼の喪失が起これば、エンジニアはテストの失敗に反応することをやめ、テストスイートの提供する価値が全部削がれてしまう。我々の経験が示唆するのは、**信頼不能性が1%に接近すると、テストは価値を失い始める**ということだ。Googleでは、信頼不能テストの割合は約0.15%あたりをうろついており、これは毎日数千の信頼不能テストが起こっているということだ。我々は、エンジニアリングを行う時間を信頼不能テストの修正のために積極的に投資するなどして、信頼不能テストを制御下にとどめるよう奮闘している。



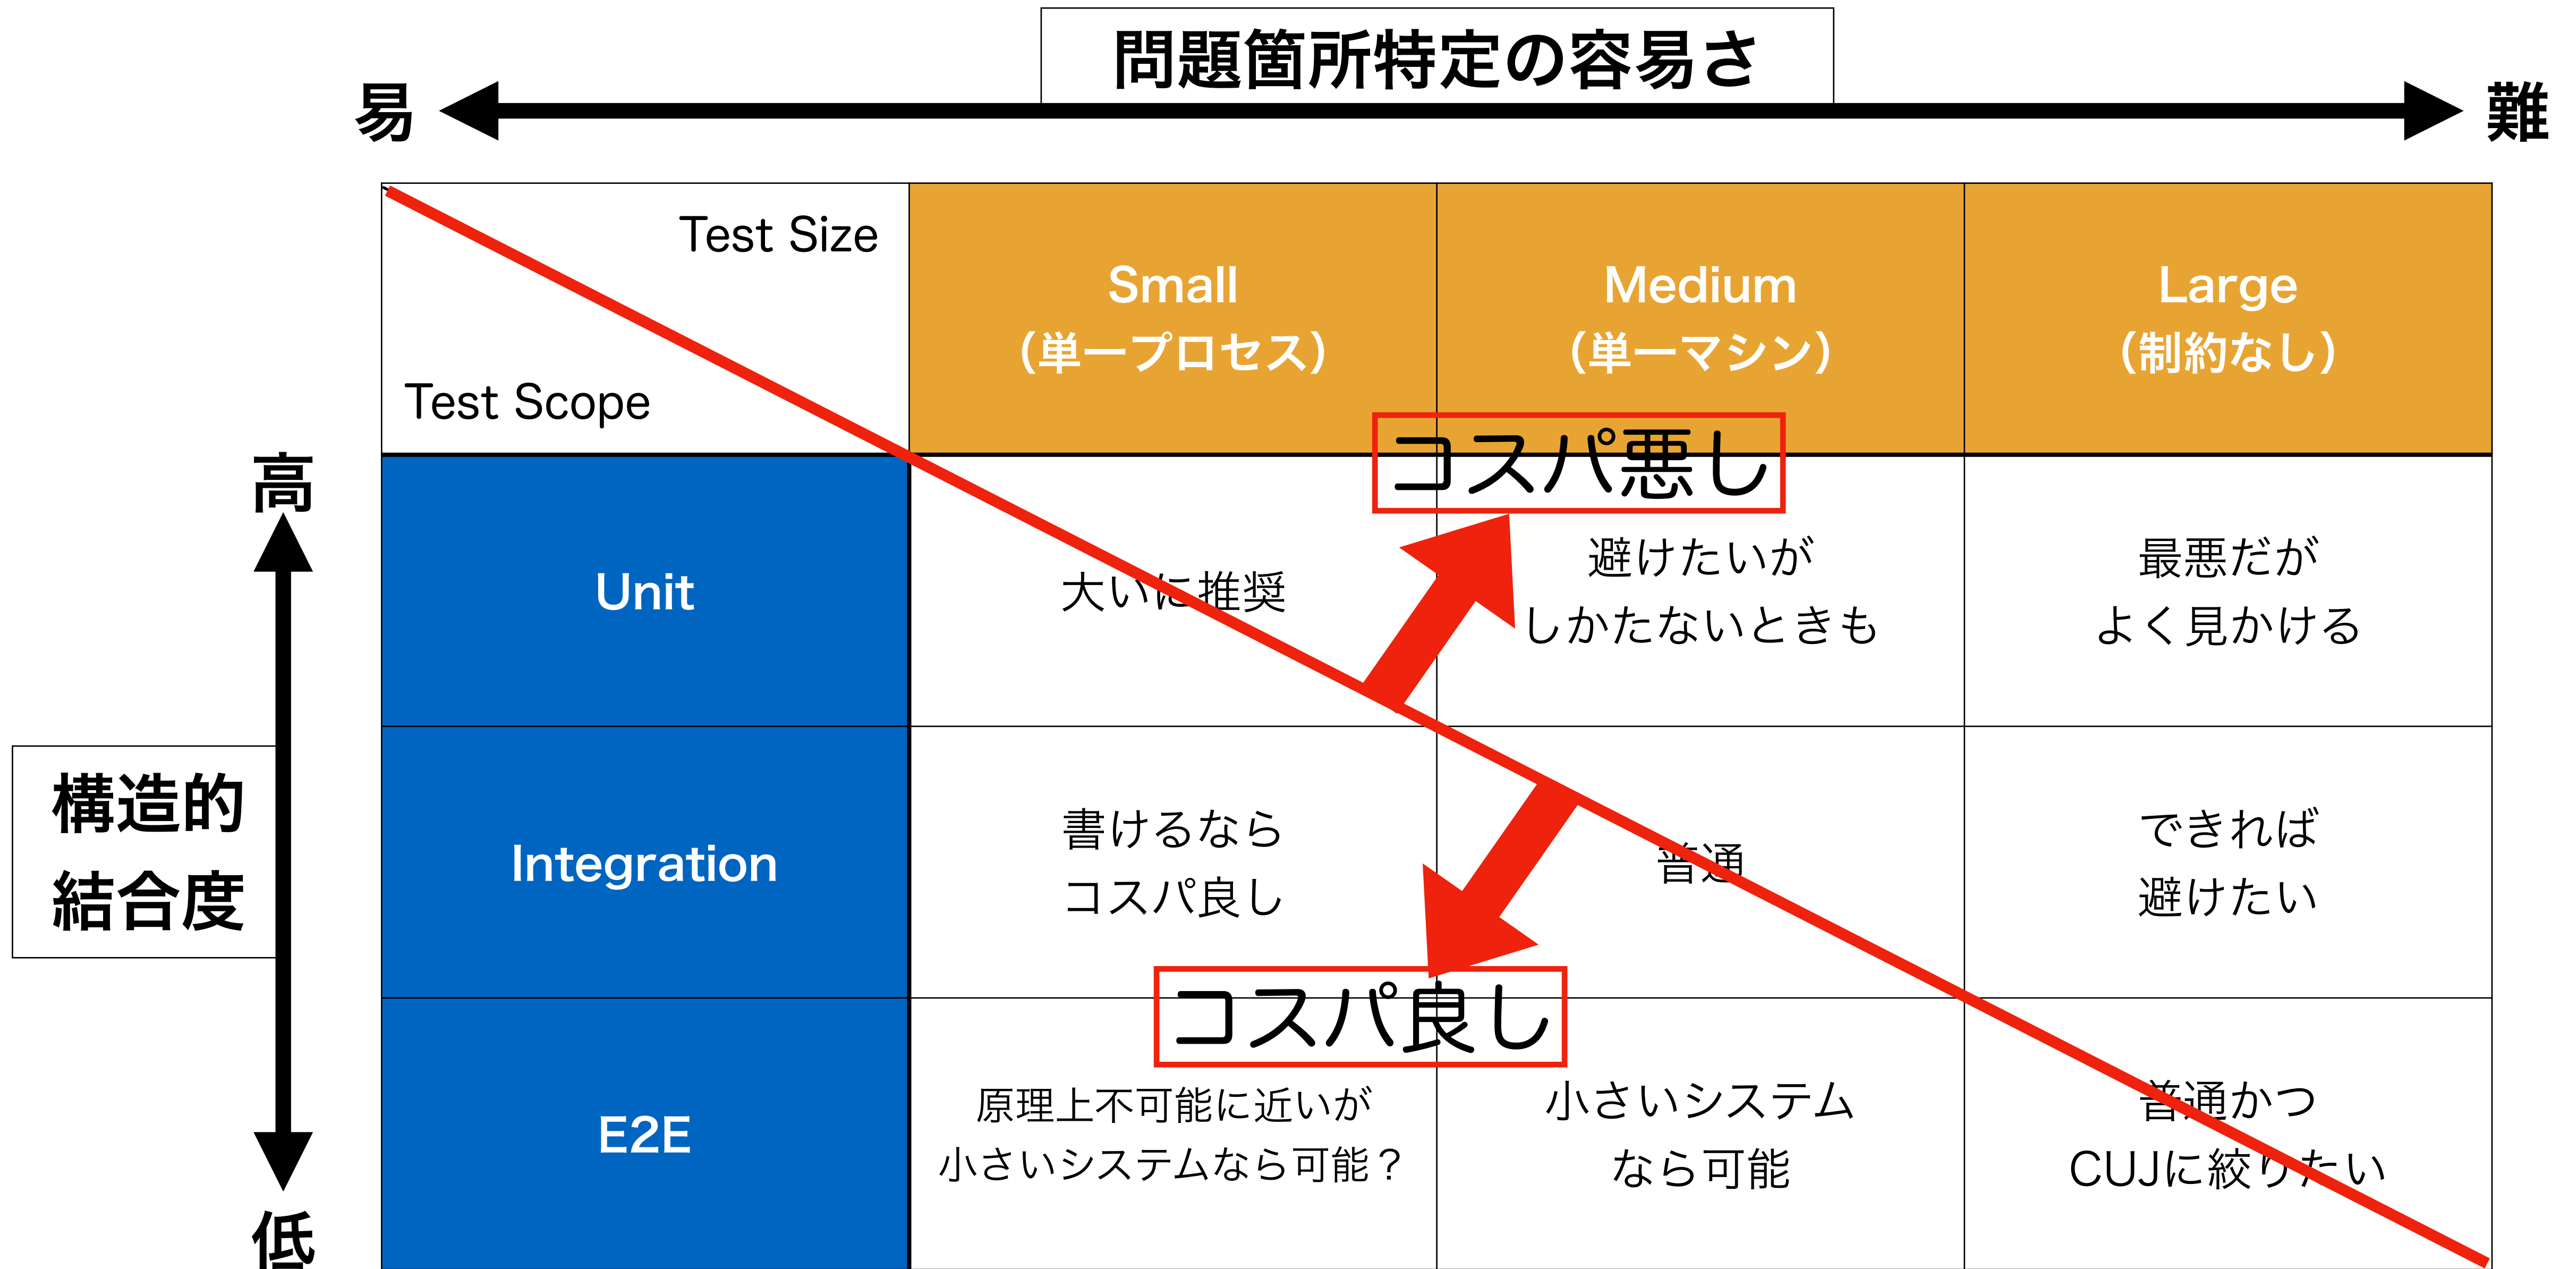
偽陽性と偽陰性のパターン

- 偽陽性
 - 脆いテスト (brittle test, fragile test)
 - 信頼不能テスト (flaky test)
- 偽陰性
 - 空振り
 - カバレッジ不足、テスト不足
 - 自作自演

Test Scope と Test Size

問題箇所特定の容易さ				
易 ← → 難				
構造的結合度	Test Size		Test Scope	
	Small (単一プロセス)		Medium (単一マシン)	
	Large (制約なし)			
高 ↓ 低	Unit		Integration	
	E2E			
	大いに推奨		避けたいが しかたないときも	
	書けるなら コスパ良し		普通	
	原理上不可能に近いが 小さいシステムなら可能?		小さいシステム なら可能	
			普通かつ CUJに絞りたい	

Test Scope と Test Size



偽陽性と偽陰性のパターン

- 偽陽性
 - 脆いテスト (brittle test, fragile test)
 - 信頼不能テスト (flaky test)
- 偽陰性
 - 空振り
 - カバレッジ不足、テスト不足
 - 自作自演

自作自演の例: テスト対象ロジックのテストコードへの漏れ出し

// プロダクトコード

```
class Item {
```

```
  // コンストラクタ割愛
```

```
  tax_amount() {
```

```
    const rate = (this.tax_rate / 100);
```

```
    return (this.price / (1 + rate)) * rate;
```

```
  }
```

```
}
```

1円未満の端数が発生する
バグがある

// テストコード

```
it('税込価格から税額を返す', () => {
```

```
  const item = new Item('技評茶', 130, 8);
```

```
  const expected = (130 / (1 + (8 / 100))) * (8 / 100);
```

```
  assert.equal(item.tax_amount(), expected);
```

```
});
```

テストコードの方も同じロジックで
期待値を計算しているので
テストが成功してしまう



Agenda

信頼性の高い

実行結果に

短い時間で到達する



状態を保つ

自動テスト文化とは

自動テスト文化とは

大量のテストスイートの作成と保守には大変な労力が要る。コードベースが大きくなるにつれて、テストスイートもまた大きくなるだろう。テストスイートは、不安定さや遅延等の問題に直面し始めることだろう。それらの問題への対処を怠ると、テストスイートは役立たずになってしまう。テストの価値は、エンジニアがテストに寄せる信頼に由来していることを心に留めておくべきだ。テストが生産性を吸い込む底なし沼となり、トイル^{†2}と不確実性を絶えず誘発するようになれば、エンジニアはテストへの信頼を失くし、ワークアラウンドを探し始めるだろう。駄目なテストスイートは、テストスイートが全くない場合よりたちが悪い。

『Googleのソフトウェアエンジニアリング』 pp.244-245


要約すると、健全な自動テスト文化は、テストを書く作業の分担共有を皆に促す。そのような文化は、定期的なテスト実行をも担保する。最後に、そしてともすれば最も重要な点として、そのような文化は、テストのプロセスに存在する高い信頼性を維持するために、破綻したテストの迅速な修正を重視している。

『Googleのソフトウェアエンジニアリング』 p.249




テストコードのメンテナンスと向き合う

理想




現実



『xUnit Test Patterns』より

自動テスト文化とは

- テスト自動化に夢を見ない
- 自動テストのメンテナンスに全員が腹落ちする
- 自動テストのメンテナンスコストを下げる努力を怠らない



自動テスト文化とは、自動テストの重要性和保守性（理解容易性、変更容易性）を組織、チームが理解し、改善努力を継続的に行う文化



テストにコストがかかる
ことの解決方法は、テスト
をやめることではありません。
うまくなること
です。

-- Sandi Metz

『オブジェクト指向設計実践ガイド』 p.239

オブジェクト指向設計 実践ガイド

Practical Object-Oriented Design in Ruby

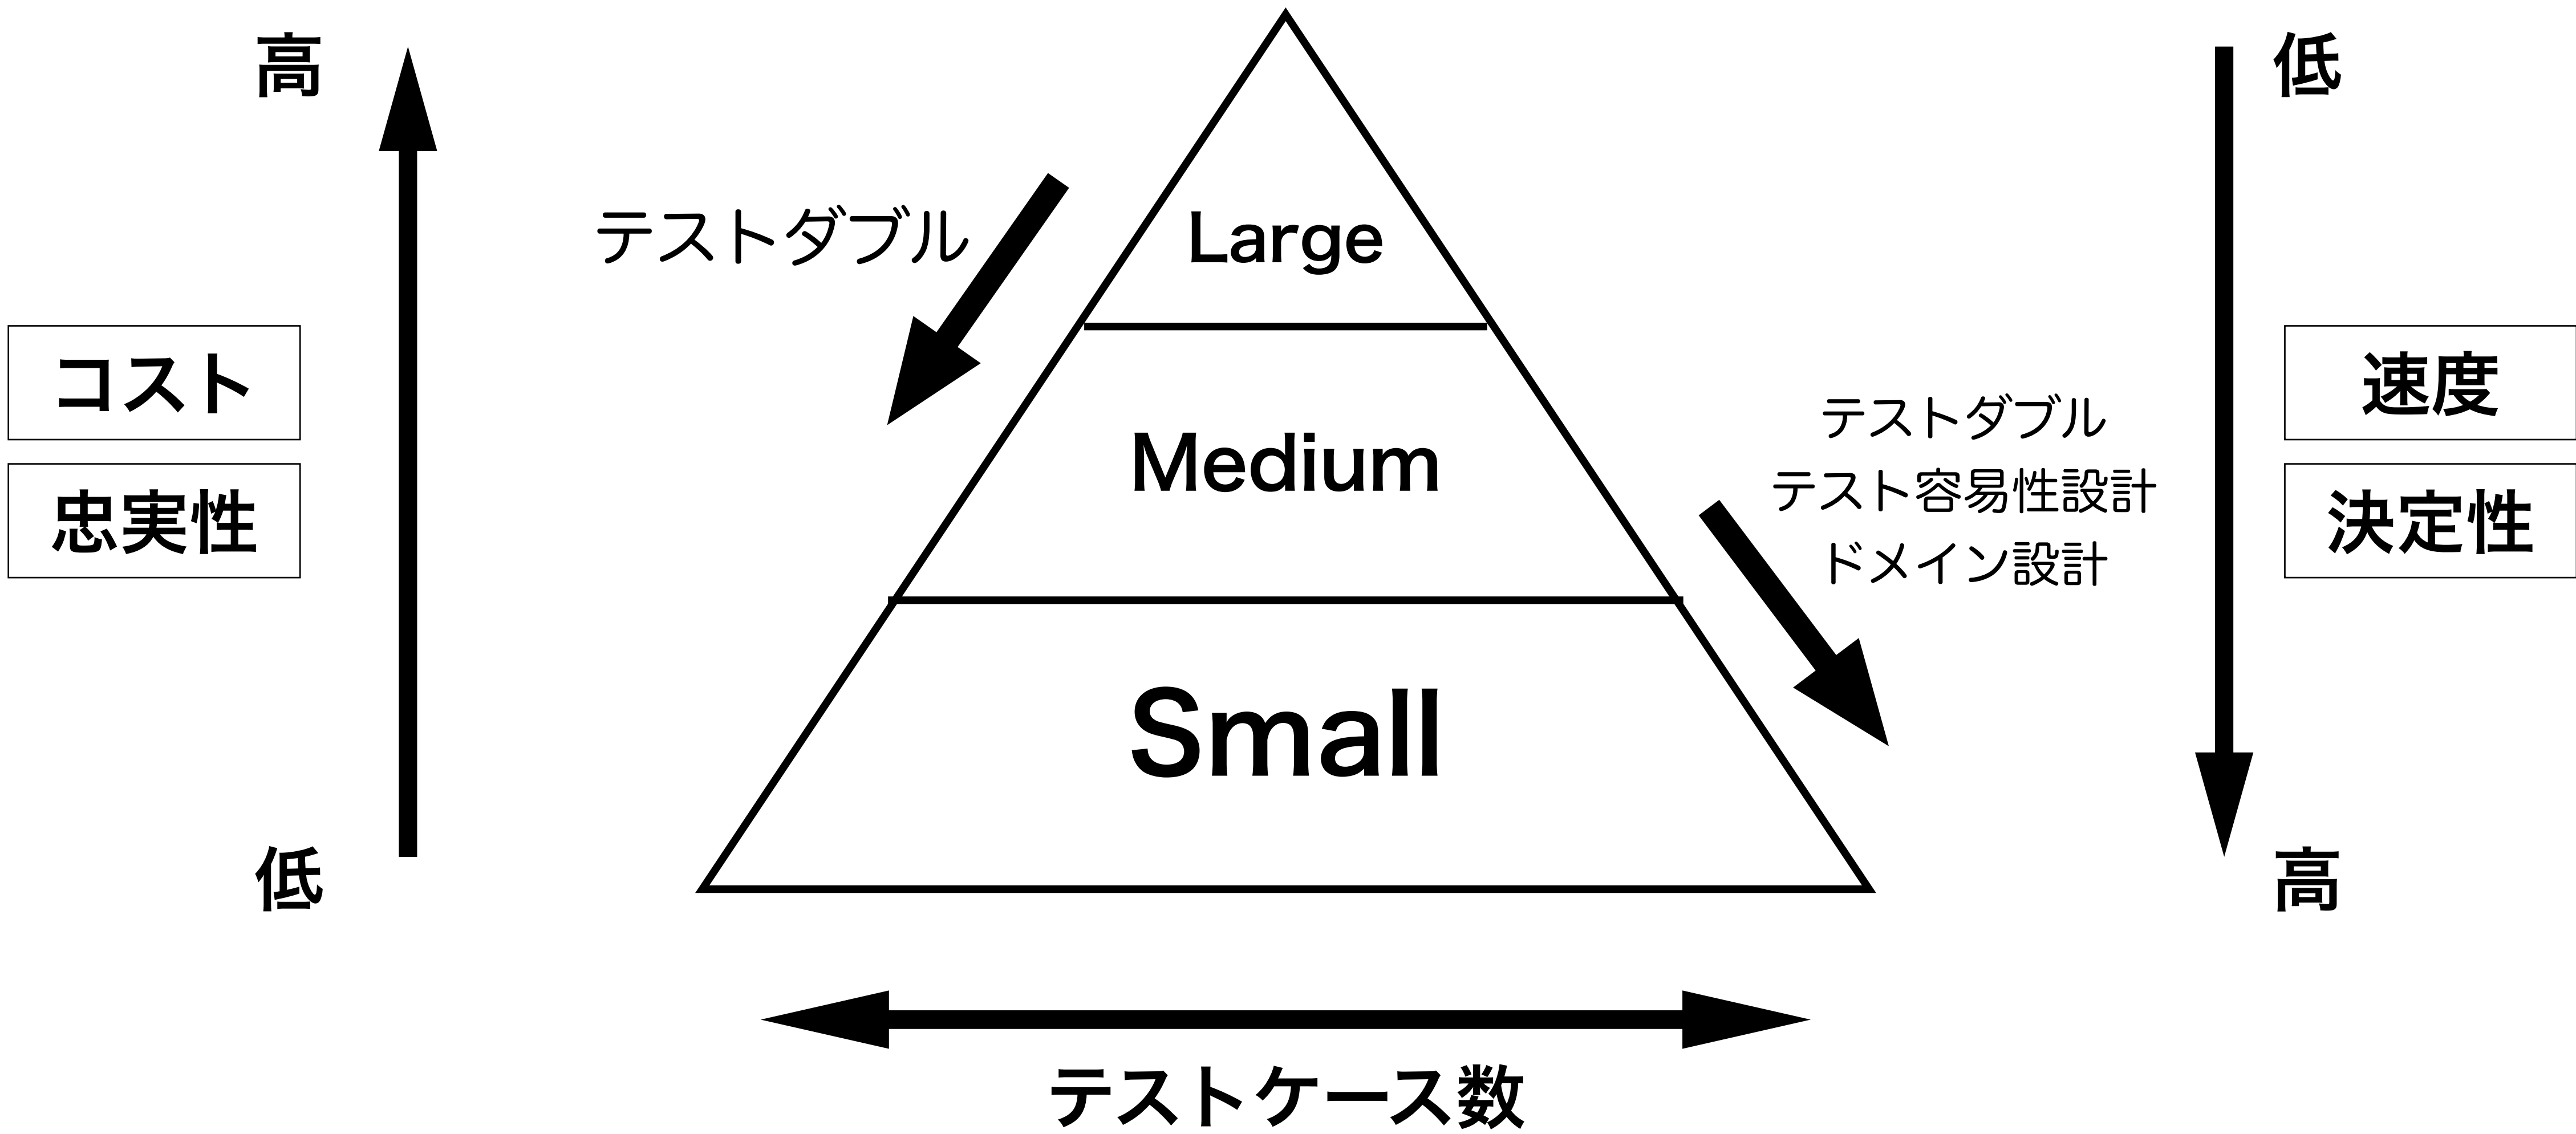
Rubyでわかる
進化しつづける柔軟なアプリケーションの育て方

Sandi Metz (著) 高山泰基 (訳)

どのような目的を持って
ソフトウェアを開発していますか？
オブジェクト指向設計の名著として
大ヒットした書籍がついに日本上陸。
適切な視点を手に入れることで、
役に立ち、実装も楽しくなるような
コード構成を実現できます。



まとめ: テストダブルでサイズダウンして、各サイズをピラミッド型に配置し、テスト全体の信頼性を維持する



ご清聴ありがとうございました

